¿Cómo predecir un súper hit?

Un análisis comparativo de modelos de popularidad musical

Catalina Gallardo Manuel Elorga

E337: Big Data — Universidad de San Andrés

Resumen

La popularidad musical en plataformas de streaming está extremadamente concentrada: una fracción mínima de canciones acumula la mayor parte de la atención. Este trabajo compara dos maneras de identificar a esas canciones excepcionales —las que llegan al 1 % más popular— usando un panel de 114,714 canciones observadas en 2018 y 2019. La primera aprovecha únicamente la estructura estadística de la distribución de popularidad, ajustando una ley de potencia por máxima verosimilitud sobre la popularidad del año anterior. La segunda es un Random Forest que utiliza exclusivamente los atributos acústicos de cada canción. El contraste es nítido: la popularidad pasada identifica a los súper hits con un AUC cercano a uno, mientras que los atributos acústicos, aunque ordenan a las canciones bastante mejor que el azar, quedan muy por detrás y recuperan apenas una fracción mínima de los súper hits. El éxito extremo resulta ser muy persistente en el tiempo, pero no se deja explicar por las características sonoras de la canción.

1. Introducción

La industria musical se transformó con la llegada de las plataformas digitales de streaming. Spotify, que concentra una porción dominante del mercado, publica para cada canción un *popularity score* entre 0 y 100. La distribución de ese score está lejos de ser simétrica: la mayoría de las canciones se agrupa en valores bajos, mientras unas pocas alcanzan niveles muy altos. Esa asimetría no es un detalle estadístico sino el rasgo central del mercado, y es lo que vuelve interesante la pregunta por el éxito extremo.

De ahí surge una pregunta con consecuencias prácticas para artistas, sellos y plataformas: **¿se puede anticipar cuáles canciones van a alcanzar el éxito extremo?** Y, sobre todo, ¿con qué información? Hay dos respuestas posibles, conceptualmente muy distintas:

1. **La estructura del mercado.** Si la popularidad se distribuye con una cola pesada, la propia forma de la distribución indica cuán probable es superar un umbral alto. Esta vía no mira a la canción: mira al mercado en el que compite.

2. **Los atributos de la canción.** Si el éxito depende de cualidades sonoras —qué tan bailable, enérgica o acústica es— entonces debería poder predecirse a partir de esos atributos. Es el enfoque dominante en la literatura, que reporta buenos desempeños con algoritmos de clasificación (Pareek et al., 2022; Saragih, 2023; Dimolitsas et al., 2023).

Este trabajo pone las dos a competir sobre los mismos datos y con la misma regla de evaluación. La pregunta que organiza el análisis es cuánta de la estructura de cola que exhibe la popularidad logra recuperar un modelo de aprendizaje automático que solo observa atributos acústicos.

2. Datos

2.1. Fuente y construcción

Partimos de dos bases publicadas en Kaggle (Gelo, 2019) con el score de popularidad y los atributos acústicos de canciones de Spotify, medidos en 2018 y en 2019. Las bases fueron construidas con el endpoint de *audio features* de la API de Spotify, que desde entonces fue discontinuado; esto hace que los datos no sean reproducibles hoy desde la fuente original, y es una de las razones por las que el repositorio conserva los archivos crudos.

Para enriquecer el análisis consultamos la API de Spotify y agregamos, para cada canción, metadata de álbum y de artista: fecha de publicación, tipo de álbum, número de pista, si la canción es explícita y la cantidad de artistas acreditados. A partir de la fecha de publicación construimos la edad de la canción.

2.2. Limpieza

Eliminamos canciones duplicadas por identificador, descartamos las que no tienen fecha de publicación recuperable —típicamente porque fueron dadas de baja de la plataforma— y excluimos aquellas cuya fecha de publicación es posterior al año de medición, que corresponden a reediciones o versiones y tendrían una edad negativa.

El análisis se realiza sobre el panel de canciones presentes en ambos años, que permite observar la misma canción en dos momentos. Quedan 114,714 canciones.

2.3. Descripción

Cuadro 1: Estadística descriptiva del score de popularidad de Spotify.

Año	N	Media	Desvío	p50	p99	Max
2018	115373	24.25	17.90	22.00	70.00	100
2019	129436	24.17	19.67	22.00	72.00	100

La Tabla 1 muestra el rasgo que motiva el trabajo. La popularidad media ronda los 24 puntos sobre 100 y la mediana está en 22, pero el percentil 99 se ubica en 70 y el máximo alcanza el tope de la escala. La distribución es estable entre años en sus momentos centrales, de modo que lo que cambia no es el nivel general de popularidad sino qué canciones ocupan el extremo.

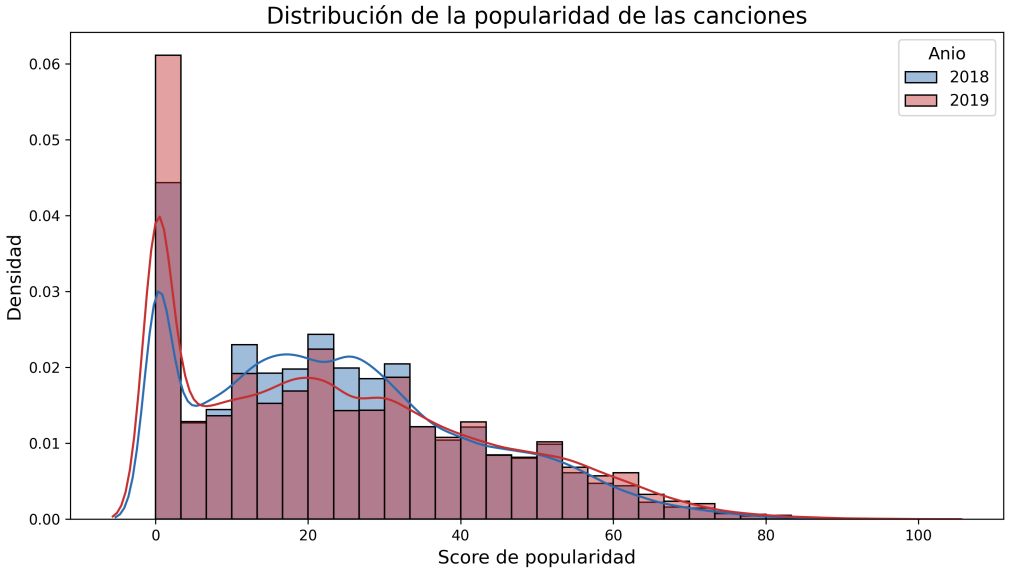
Cuadro 2: Canciones más populares de cada año (score entre paréntesis).

2018	2019
thank u, next — Ariana Grande (100)	Con Calma — Daddy Yankee (100)
Taki Taki (with Selena Gomez, Ozuna & Cardi B) — DJ Snake (99)	Wow. — Post Malone (98)
MIA (feat. Drake) — Bad Bunny (97)	Sucker — Jonas Brothers (98)

3. Metodología

3.1. Definición de súper hit

Definimos como súper hit a toda canción que en 2019 se ubica en el percentil 99 o más alto de popularidad, lo que corresponde a un score de 70 puntos o más. Bajo esta definición, 1.03 %



Nota: el score de popularidad de Spotify va de 0 (menos popular) a 100 (más popular).

Figura 1: Distribución del score de popularidad en 2018 y 2019. Las dos distribuciones son casi indistinguibles y marcadamente asimétricas a la derecha.

de las canciones del panel son súper hits. El fuerte desbalance de clases no es un inconveniente del diseño: es exactamente el fenómeno que se quiere estudiar.

3.2. Modelo 1: ley de potencia estimada por máxima verosimilitud

Una variable sigue una ley de potencia si su densidad decae como $p(x) \propto x^{-\alpha}$ por encima de un umbral $x_{\text{mín}}$. La función de supervivencia correspondiente, es decir la probabilidad de superar un valor dado, es

$$P(X \geq x) \;=\; \left(\frac{x}{x_{\text{mín}}}\right)^{1-\alpha}, \qquad x \geq x_{\text{mín}}. \tag{1}$$

Estimamos α y $x_{\text{mín}}$ por máxima verosimilitud siguiendo el procedimiento de Clauset et al. (2009), implementado en el paquete `powerlaw` (Alstott et al., 2014). La estimación por máxima verosimilitud es preferible a una regresión log-log sobre el histograma, que produce estimadores sesgados en colas pesadas.

El ajuste se realiza sobre la popularidad de 2018 en la muestra de entrenamiento y arroja $\hat{\alpha} = 2.92$ y $\hat{x}_{\text{mín}} = 22$. Para cada canción de la muestra de testeo evaluamos la ecuación (1) en su popularidad de **2018** y usamos $1 - P(X \geq x)$ como puntaje: el percentil estimado que la canción ocupa en la distribución. Para valores por debajo de $x_{\text{mín}}$ la ley no está definida —el ajuste describe solo la cola— y el puntaje se fija en cero.

Conviene subrayar que este modelo utiliza la popularidad del año anterior y no la del año que se predice. Así, la predicción es genuinamente fuera de muestra en el tiempo, y la comparación con el Random Forest es una comparación entre dos conjuntos de información distintos: la trayectoria previa de la canción frente a sus cualidades sonoras.

3.3. Modelo 2: Random Forest sobre atributos acústicos

El segundo modelo es un Random Forest (Breiman, 2001), el algoritmo que la literatura revisada señala como el de mejor desempeño para esta tarea. Utiliza trece atributos acústicos provistos por Spotify —*acousticness*, *danceability*, duración, *energy*, *instrumentalness*, *key*, *liveness*, *loudness*, *mode*, *speechiness*, *tempo*, *time signature* y *valence*— más la cantidad de artistas

acreditados, un indicador de contenido explícito y la edad de la canción. Deliberadamente no incluye la popularidad pasada, de modo que su conjunto de información sea el de los atributos de la canción.

Los hiperparámetros se eligen por validación cruzada estratificada de cinco pliegues sobre la muestra de entrenamiento (James et al., 2021), maximizando el AUC. Elegir en función del AUC y no de la proporción de aciertos es necesario con una clase positiva del 1 %: una regla que nunca predice un hit ya alcanza un 99 % de aciertos, de manera que la proporción de aciertos no distingue entre candidatos.

3.4. Regla de decisión y evaluación

Dividimos el panel en entrenamiento (70 %) y testeo (30 %) de forma estratificada, con 80,299 y 34,415 canciones respectivamente. Todas las métricas que se reportan corresponden a la muestra de testeo.

Por el mismo desbalance, clasificar como positivo todo caso con probabilidad estimada mayor a 0.5 no es informativo: casi ningún caso supera ese valor y precisión y sensibilidad colapsan a cero para ambos modelos. Calibramos entonces el umbral de cada modelo de modo que clasifique como positiva aproximadamente la misma proporción de casos que la tasa base, lo que sobre la muestra de testeo equivale a 354 predicciones positivas.

La calibración no puede ser exacta, porque ninguno de los dos puntajes es continuo y se producen empates en el valor de corte. El caso de la ley de potencia es el más marcado: la popularidad es una variable entera y el puntaje es una función de ella, de modo que toma pocos valores distintos y todas las canciones con la misma popularidad de 2018 reciben el mismo puntaje, y entran o salen juntas. El Random Forest tiene el mismo problema en menor medida, porque su probabilidad estimada es la proporción de árboles que votan por la clase positiva y sólo puede tomar múltiplos de uno sobre el número de árboles. La ley de potencia emite así 408 predicciones positivas y el Random Forest 375, frente a las 354 que marcaría la tasa base y a 353 súper hits efectivos en la muestra de testeo. Las matrices de confusión son comparables con esa salvedad, que juega en contra de la ley de potencia: al emitir más predicciones positivas, su precisión se calcula sobre una base más exigente. El AUC, que no depende del umbral elegido, no está afectado por este problema y se reporta como medida global de capacidad de discriminación.

4. Resultados

4.1. ¿Es realmente una ley de potencia?

Antes de usar la ley de potencia conviene preguntarse si describe bien a los datos. La Figura 2 compara la función de supervivencia empírica con la ley de potencia ajustada y con una lognormal. El test de cociente de verosimilitudes normalizado entre ambas alternativas arroja $R = -83.67$ con $p < 0.001$, lo que favorece a la lognormal de manera estadísticamente significativa.

Conviene entonces ser preciso sobre lo que se puede afirmar. La popularidad tiene una cola derecha pesada, y ese hecho es robusto. Pero la ley de potencia no es la mejor descripción paramétrica disponible, y además el score está acotado entre 0 y 100, mientras que una ley de potencia genuina no tiene cota superior. La ley de potencia funciona aquí como un resumen paramétrico útil y parsimonioso de la cola, no como el proceso generador de los datos. Lo que se evalúa a continuación es su desempeño como herramienta de ordenamiento, que no depende de que el ajuste sea el mejor posible.

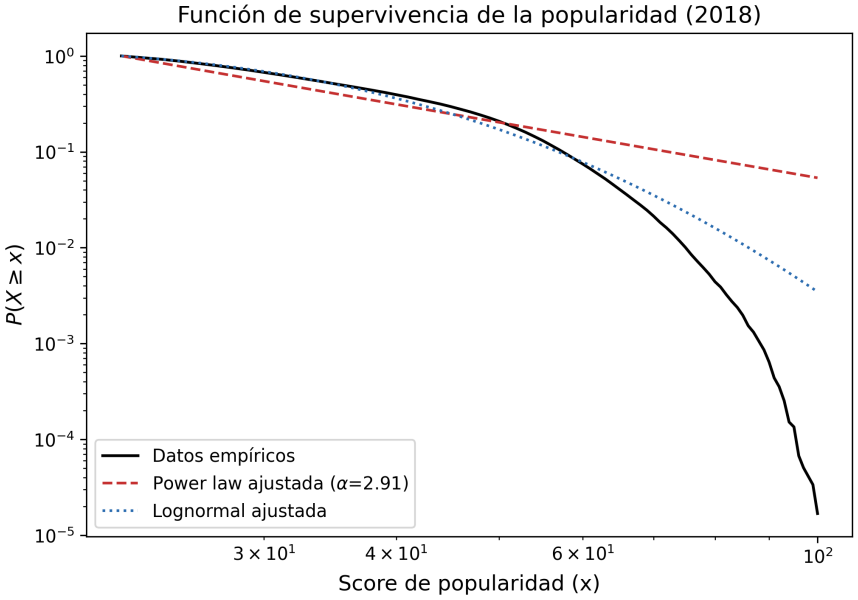


Figura 2: Función de supervivencia de la popularidad en 2018, en escala logarítmica, junto con los ajustes de una ley de potencia y de una lognormal.

Cuadro 3: Desempeño en la muestra de testeo para identificar canciones del top 1 % de popularidad en 2019. El umbral de clasificación de cada modelo se calibra a la tasa base de positivos.

Modelo	Accuracy	Precision	Recall	F1	AUC
Ley de potencia	0.995	0.706	0.816	0.757	0.997
Random Forest	0.980	0.048	0.051	0.049	0.761
RF + popularidad pasada	0.995	0.744	0.748	0.746	0.986

4.2. Comparación de modelos

La Tabla 3 contiene el resultado central del trabajo, y la diferencia es grande. La ley de potencia aplicada sobre la popularidad del año anterior ordena a las canciones casi perfectamente: su AUC es prácticamente uno y, con el umbral calibrado, acierta en torno a siete de cada diez de sus predicciones positivas mientras recupera una amplia mayoría de los súper hits efectivos. El Random Forest sobre atributos acústicos, en cambio, queda muy por detrás. Su AUC es moderado —claramente por encima del azar, de modo que los atributos acústicos no son puro ruido— pero la distancia con la ley de potencia es enorme, y lo decisivo para la pregunta del trabajo es que con el umbral calibrado recupera una fracción mínima de los súper hits: tanto su precisión como su sensibilidad quedan por debajo del cinco por ciento. Los atributos acústicos sirven para ordenar canciones, pero no para identificar a las excepcionales.

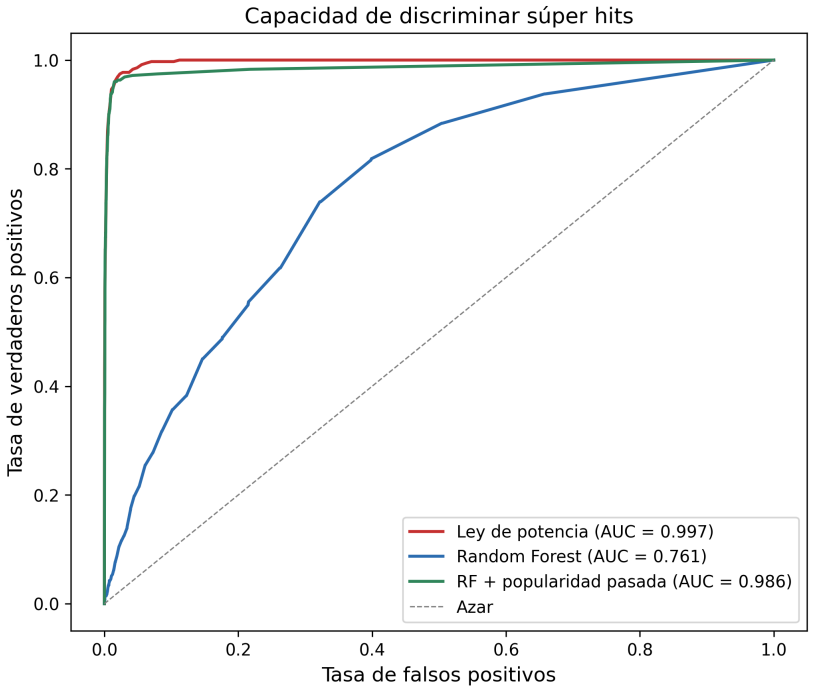


Figura 3: Curvas ROC en la muestra de testeo. La ley de potencia sobre popularidad pasada domina al Random Forest sobre atributos acústicos en todo el rango.

La tercera fila de la tabla sirve de diagnóstico. Si se le entrega al Random Forest la popularidad pasada junto con los atributos acústicos, su desempeño salta al nivel de la ley de potencia. Es decir: la señal estaba disponible, y el modelo es capaz de aprovecharla cuando la recibe. Su bajo desempeño en la segunda fila no se explica por una limitación del algoritmo ni por un problema de ajuste, sino por la escasa información que los atributos acústicos contienen respecto del éxito extremo.

Cuadro 4: Matrices de confusión en la muestra de testeo. VN: verdaderos negativos, FP: falsos positivos, FN: falsos negativos, VP: verdaderos positivos.

Modelo	VN	FP	FN	VP
Ley de potencia	33942	120	65	288
Random Forest	33705	357	335	18
RF + popularidad pasada	33971	91	89	264

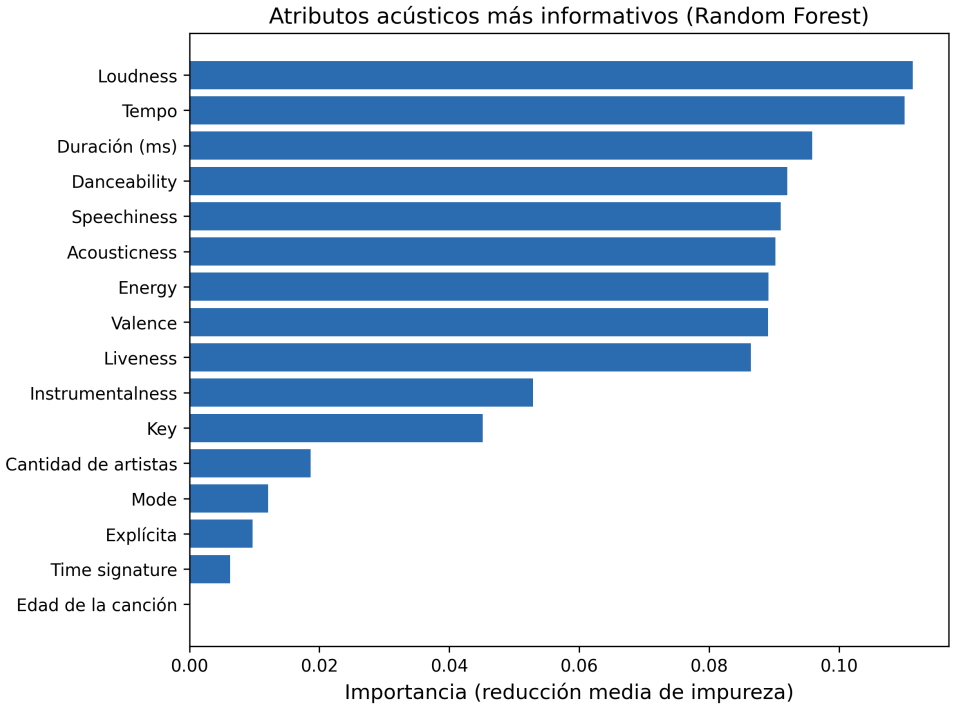


Figura 4: Importancia relativa de los atributos en el Random Forest. Aun los más informativos aportan poco en términos absolutos.

4.3. Robustez

Cabe preguntarse si el pobre desempeño de los atributos acústicos se debe a lo exigente de la definición de súper hit. La Tabla 5 y la Figura 5 reestiman el modelo moviendo el umbral de popularidad desde 30 puntos —donde un tercio de las canciones califica como hit— hasta 80. Para aislar el efecto del umbral, este ejercicio mantiene fijos los hiperparámetros en lugar de volver a elegirlos en cada punto, de modo que sus valores de AUC no son estrictamente comparables con los de la Tabla 3. El AUC permanece prácticamente constante en torno a 0.72 en todo el rango.

Cuadro 5: Desempeño del Random Forest sobre atributos acústicos según el umbral de popularidad usado para definir un hit. La última columna es la proporción de aciertos de una regla que nunca predice un hit.

Umbral	Positivos (%)	AUC	Aciertos triviales
30	34.097	0.707	0.659
40	19.645	0.718	0.804
52	8.530	0.724	0.915
60	3.851	0.736	0.961
70	1.027	0.725	0.990
80	0.201	0.681	0.998

La conclusión no es entonces un artefacto del desbalance de clases: los atributos acústicos informan poco sobre la popularidad en cualquier punto de la distribución.

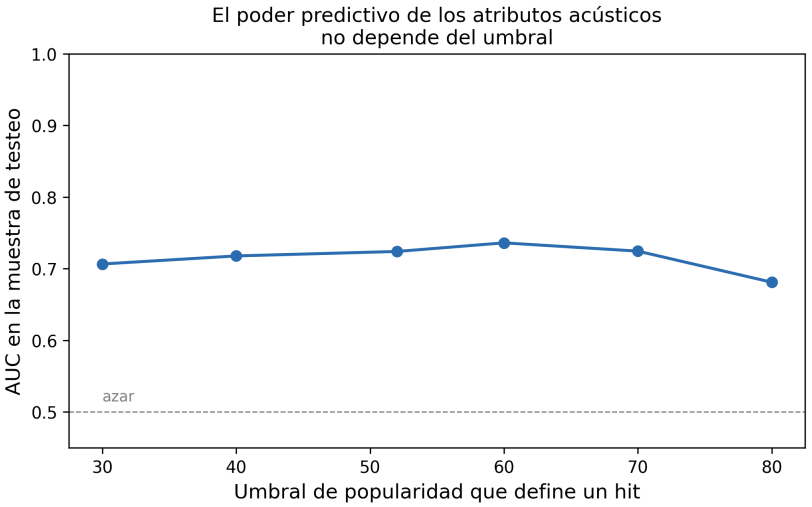


Figura 5: AUC del Random Forest sobre atributos acústicos según el umbral de popularidad que define un hit.

5. Discusión

5.1. Relación con la literatura

Nuestro resultado para los atributos acústicos es sustancialmente más pesimista que el de los trabajos revisados, que reportan desempeños del orden del 83 % al 89 % (Pareek et al., 2022; Dimolitsas et al., 2023). Hay al menos tres explicaciones posibles, no mutuamente excluyentes.

La primera es la métrica. Varios de estos trabajos informan proporción de aciertos sobre muestras desbalanceadas sin contrastarla contra la tasa base. Con un 8 % de casos positivos, una regla que nunca predice un hit ya alcanza el 92 % de aciertos, de modo que un 89 % informado de esa manera no constituye evidencia de capacidad predictiva. La última columna de la Tabla 5 hace explícito ese punto de comparación.

La segunda es el conjunto de atributos. Varios trabajos incorporan el género musical, el artista o métricas sociales externas a la plataforma. Son predictores razonables de popularidad, pero no son atributos acústicos: se acercan más a información de trayectoria que a cualidades sonoras de la canción.

La tercera es la definición de la variable dependiente. Nuestro objeto es el éxito extremo. Distinguir una canción muy popular de una de popularidad media es una tarea distinta, y más fácil, que identificar al 1 % superior.

5.2. Interpretación

El patrón que surge de los datos tiene una lectura natural. El éxito extremo es fuertemente persistente: saber que una canción estaba en el extremo superior el año pasado basta para anticipar que seguirá allí. Pero esa persistencia no se explica por lo que la canción *es* en términos sonoros. Es consistente con mecanismos acumulativos —influencia social, inclusión en *playlists*, sistemas de recomendación que amplifican lo que ya es popular— más que con un conjunto de cualidades intrínsecas que hagan exitosa a una canción. Salganik et al. (2006) documentan experimentalmente esta clase de dinámica en mercados culturales: cuando los participantes observan las elecciones de otros, el éxito se vuelve a la vez más desigual y menos predecible a partir de la calidad intrínseca.

Para quien quisiera usar estos resultados, la implicancia es incómoda: no parece haber una receta sonora del súper hit. Las variables que sí predicen son las que describen la posición que la canción ya ocupa.

5.3. Limitaciones

Hay cuatro que conviene explicitar.

El horizonte es corto. Observamos 2018 y 2019. Un año de distancia hace que la persistencia de la popularidad sea casi mecánica, y el ejercicio dice poco sobre cuán predecible es el éxito de una canción nueva, que es la pregunta de interés para quien está por lanzarla.

La variable dependiente es opaca. Spotify no documenta cómo se construye el *popularity score*. Se sabe que combina reproducciones recientes con recencia, pero su definición exacta es privada, de modo que no puede descartarse que incorpore componentes que generen persistencia por construcción.

No hay identificación causal. Todo lo reportado es predictivo. Nada permite afirmar que modificar un atributo acústico cambiaría la probabilidad de éxito.

El panel sobrevive. Al quedarnos con las canciones presentes en ambos años excluimos las que desaparecieron de la plataforma, que probablemente sean las menos populares. Esto puede comprimir la parte baja de la distribución.

6. Conclusión

Comparamos dos maneras de identificar a las canciones del 1 % más popular de Spotify sobre un panel de 114,714 canciones observadas en 2018 y 2019. Una ley de potencia ajustada por máxima verosimilitud sobre la popularidad del año anterior las identifica casi perfectamente; un Random Forest que solo observa atributos acústicos ordena mejor que el azar pero recupera una fracción mínima de los súper hits, y el resultado se mantiene en cualquier umbral de popularidad. Cuando se le agrega la popularidad pasada, el mismo algoritmo alcanza el desempeño de la ley de potencia, lo que confirma que la limitación está en la información disponible y no en el método.

La respuesta a la pregunta del título es entonces doble. Un súper hit se predice muy bien, pero a partir de su trayectoria, no de su sonido. En un mercado donde la atención se concentra de manera tan desigual, lo que mejor anticipa el éxito futuro es el éxito pasado.

A. Correcciones respecto de la versión original

Esta versión del análisis corrige tres problemas de la implementación original que afectaban los resultados. Se documentan por transparencia, ya que modifican las conclusiones del trabajo.

Circularidad. El modelo de ley de potencia calculaba la probabilidad a partir de `popularity_2019`, que es la misma variable con la que se define la etiqueta de súper hit. El modelo predecía la variable usando la variable misma, de modo que una implementación correcta de esa especificación habría dado un AUC de exactamente uno por construcción. En esta versión la ley de potencia se evalúa sobre `popularity_2018`.

Fórmula. La implementación original usaba $(x/x_{99})^{-(\alpha+1)}$, con el exponente equivocado y el percentil 99 en lugar de $x_{\text{mín}}$. Esa expresión es decreciente en la popularidad —a canción más popular le asignaba menor probabilidad de ser un hit— y toma valores mayores que uno, lo que es imposible para una probabilidad. La expresión correcta es la ecuación (1).

Umbral de decisión. Clasificar como positivo todo caso con probabilidad mayor a 0.5 no funciona con una tasa base del 1 %: casi ningún caso supera ese valor. Esta versión calibra el umbral de cada modelo a la tasa base.

Adicionalmente, la búsqueda de hiperparámetros original optimizaba la proporción de aciertos, que con un 1 % de positivos no discrimina entre candidatos; aquí se optimiza el AUC. La

validación cruzada usaba pliegues sin estratificar, que con una clase positiva tan chica puede dejar pliegues con muy pocos positivos; aquí se estratifica. Los filtros de limpieza que comparaban una fecha contra el entero cero —una comparación que nunca es verdadera, de modo que no eliminaban ninguna observación— se reemplazaron por una verificación de valores faltantes.

Referencias

Jeff Alstott, Edward Bullmore, and Dietmar Plenz. powerlaw: A python package for analysis of heavy-tailed distributions. *PLoS ONE*, 9(1):e85777, 2014.

Leo Breiman. Random forests. *Machine Learning*, 45(1):5–32, 2001.

Aaron Clauset, Cosma Rohilla Shalizi, and M. E. J. Newman. Power-law distributions in empirical data. *SIAM Review*, 51(4):661–703, 2009.

Ioannis Dimolitsas, Spyridon Kantarelis, and Afroditi Fouka. SpotHitPy: A study for ML-based song hit prediction using spotify. arXiv:2301.07978, 2023.

Tomi Gelo. Spotify audio features. Kaggle dataset, 2019. `https://www.kaggle.com/datasets/tomigelo/spotify-audio-features`.

Gareth James, Daniela Witten, Trevor Hastie, and Robert Tibshirani. *An Introduction to Statistical Learning*. Springer, 2nd edition, 2021.

Simran Pareek, Shubham Goswami, and Divya Tiwari. Predicting music popularity using machine learning algorithm and music metrics available in spotify. *International Journal of Computer Applications*, 184(12):17–24, 2022.

Matthew J. Salganik, Peter Sheridan Dodds, and Duncan J. Watts. Experimental study of inequality and unpredictability in an artificial cultural market. *Science*, 311(5762):854–856, 2006.

Houston Sarpa Saragih. Predicting song popularity based on spotify's audio features: insights from the indonesian streaming users. *Journal of Management Analytics*, 10(4):693–709, 2023.