Base de datos

- 2018 y 2019: 130 mil datos
    - Fuente: Kaggle
    - Nivel: canción
    - Representatividad: ?? (graficar)
    - Columnas
        - Nombre del artista
        - Id de la canción
        - Nombre de la canción
        - Acousticness
        - Danceability
        - Duración en milisegundos
        - Energy
        - Instrumentales
        - Key
        - Liveness
        - Loudness
        - Mode
        - Spreechiness
        - Tempo
        - Time signature
        - Valence
        - Popularidad en 2018
        - Popularidad en 2019
- Datos 2025
    - Fuente: Spotify API
    - Columnas
        - Id del artista
        - Id del álbum
        - Nombre del álbum
        - Fecha de publicación
        - Tipo de álbum (si es un álbum, una canción single o una composición)
        - Orden (si es un sigle va a ser 1, si es un album donde esta en el álbum)

        - Explicit: dummy que vale 1 si la canción es explícita
        - Popularidad 2025
        - Cantidad de artistas
        - Id de los artistas featured
        - Nombre de los artistas featured
        - Popularidad del artista principal
        - Seguidores del artista principal
        - Popularidad de los artistas featured
        - Seguidores de los artistas featured
- Variables calculadas
    - Seguidores promedio
    - Popularidad promedio
    - Años desde que fue publicada la canción
- Limpieza de datos
    - Eliminamos canciones sin fecha
    - Convertimos explicit en dummy
    - Revisar floats/ints
    - Revisar que no haya missings

Modelo

- Y: Popularidad en 2025
- X: Id del artista, Acousticness, Danceability, Duración en milisegundos, Energy, Instrumentales, Key, Liveness, Loudness, Mode, Speechiness, Tempo, Time signature. Valence, Popularidad en 2018, Popularidad en 2019, Seguidores promedio, Popularidad promedio, Años desde que fue publicada la canción, Tipo de álbum, Id album, Orden, Explicit, Cantidad de artistas

Ideas de análisis

- Método ML: RandomForest, revisión de literatura dice que es el que mejor predice
    - Predecir la popularidad de la canción
    - Predecir la popularidad de la cancion, considerando cuanto paso desde que fue publicada
- Otros tipos de regresiones/predictores

    - Ver importancia de cada una de las variables
    - Calcular probabilidad de que una canción siga siendo popular o siga sin tanta variación

Revisión de literatura

- Predicting Music Popularity Using Machine Learning Algorithm and Music Metrics Available in Spotify

Obj→ predecir si una cancion sera popular o no usando metricas acusticas de Spotify, mediante algoritmos de clasificacion
Metologia→ Popular o no (si esta >=52 en escala de 100(rari)) Utiliza modelo de random forest!! tiene una precision mas o menos de 89% tambien usa el modelo de KNN(el de los vecinos) con 68% y el modelo de Linear Soporoso Vector Classifier → 64%
Base de datos → es la que usamos creo(kaggle)-->232.725 canciones
Variables → popularity, danceability,...
Resultados principales→ random forest es la uqe me jor precision tiene con 83% , un recall(tasa de verdaderos positivos, cuantas detecto bien el modelo) de 0,70→ detecta la mayoria de las canciones exitosas, un F1(balanceo) score de 76%--> buen balanceo entre las dos y un AUC (que tan bien separa las dos clases popular y no popular)de 91%--> buena capacidad de clasificación

- PREDICTION OF PRODUCT SUCCESS: EXPLAINING SONG POPULARITY BY AUDIO FEATURES FROM SPOTIFY DATA

Resumen del paper:
Obj→ Investiga si las características acústicas de las canciones extraídas del API de Spotify pueden explicar la popularidad de las canciones, medida por el número de reproducciones(streams) en la plataforma. → bastante parecido lo nuestro pero lo malo es uqe no sabemos como esta formada la variable popularity
Metodologia→ modelo de regresion lineal multiple(SPSS) tras un analisis correlacional
Variable dependiente→ numero de streams de una cancion de spotify(logaritmica)
Variable independiente→ danceability,... → parecido a lo nuestro
901 canciones, 10 generos distintos
Correlacion positiva → danceability
Correlacion negativa→ instrumentalness, duration, etc
R^2 → 20%

- SpotiPred: A Machine Learning Approach Prediction of Spotify Music Popularity by Audio Features
- Exploring Spotify's Music Popularity Dynamics and Forecasting with Machine Learning

Obj→ analiza como las características acusticas de canciones(energy, valance,..) influyen en la popularidad y predice tendencias futuras de exito musical mediante random forest y decision trees

Metodlogia→ Decision tree, random forest

Variables utilizadas→ danceability,...

Para el autor la mejor es random forest en vez de decision tree utilizando las siguientes metricas de evaluacion: R^2, error absoluto medio, y la raiz del error cuadratico medio. En estos dos ultimos da un valor mas bajo y en el primero un valor mas alto. Entonces es mas efectivo para predecir popularidad numerica de las canciones.

Base de datos→ kaggle

953 hit songs

Resultados principales→ presencia en playlist, año de lanzamiento

Canciones con alta energia, BPM medio y valance alto tienden a ser mas exitosas

La inclusion en varias playlists potencia su popularidad entre plataformas

- Prediction of spotify songs by popularity(no pude entrar :(

- https://researchmgt.monash.edu/ws/portalfiles/portal/563952627/502831287_oa.pdf?utm_source=chatgpt.com

Predicting song popularity based on Spotify´s audio features: insights from indonesian streaming users

Obj→ Investiga como las características de audio de spotify pueden predecir la popularidad de las canciones en Indonesia.

Metodologia→ Random forest, linear regression,...

Popularity score → escala de 0 a 100

Fuente → kaggle → 8300 canciones

Usando el R^2 el random forest fue el mas preciso

- https://indjst.org/articles/predicting-music-popularity-using-spotify-and-youtube-features?utm_source=chatgpt.com

Predicting music popularity using spotify and youtube features

Obj→ examinar si la integracion de caracterisitcas de audio de spotify y metricas de redes sociales de youtube puede predecir eficazmente la popularidad de una cancion.

Metodologia→ random forest, knn,naive bayes, support vector machine

variables → danceability,..

- metricas sociales de yt→ numero de vistas, likes, dislikes y comentarios de video de la cancion

Establece tres niveles de popularidad(baja, media, alta)basada en metricas del rendimiento diario en el top 200 de spotify

- numero de dias en el top 200
- posicion mas alta
- suma total de posiciones
- promedio de posiciones
- posicion en el dia de debut

base de datos→ canciones entre mayo y agosto de 2021. No especifica el tamaño

Resultados→ random forest supera a los otros modelos. La incorporación de métricas sociales de Yt mejoró significativamente del modelo. → esta bueno esto. se podria utilizar ya sea yt o twitter(tipo numero de tweets mencionando la cnacion, hashtags, sentimientos de los tweets, tiempo desde el lanzamiento hasta uqe se vuelve tendencia), tiktok(numero de videos que usan la cancion como audio, reproduccion total de los videos, likes)

- https://arxiv.org/abs/2301.07978?utm_source=chatgpt.com

Predicting the popularity of spotify songs using a neural work

Obj→Comparar la eficiencia de tres algoritmos de aprendizaje automatico(random forest, support vector machine y redes neuronales) en la predicción de la popularidad de canciones en spotify clasicandolas como populares o no populares.

Metodologia→random forest, support vector machine, red neuronal

Variable→ popularidad clasificaion binaria popular/no popular basada en el score de popularidad de spotify

Metricas de evaluacion: precision, recall, f1-score, exactitud

Base de datos→ datos de 160 mil canciones entre 1921 y 2020

amplia variedad de generos musicales y caracteristicas de audio proporcionadas por el spotify API

Resultados→random forest es el que mejor estima con precision y recall para ambas clases

- https://arxiv.org/abs/2301.13507?utm_source=chatgpt.com

An analysis of classification approaches for hit song prediction using engineered metadata features with lyrics and audio features

Obj→ mejorar la prediccion de canciones exitosas en el billboard hot 100 mediante el uso combinado de audio de spotify letras de canciones y metadatos novedosos

Metodologia→ random forest, regresion logistica, knn,naive bayes

variables analizadas

- danceability,..
- letra de canciones→ analisis de contenido y temas presentes en las letras
- temas del titulo de la cancion, continuidad de popularidad, clasificacion por genero
- metricas de evaluacion→ precision, auc

base de datos→ canciones del billboard hot 100

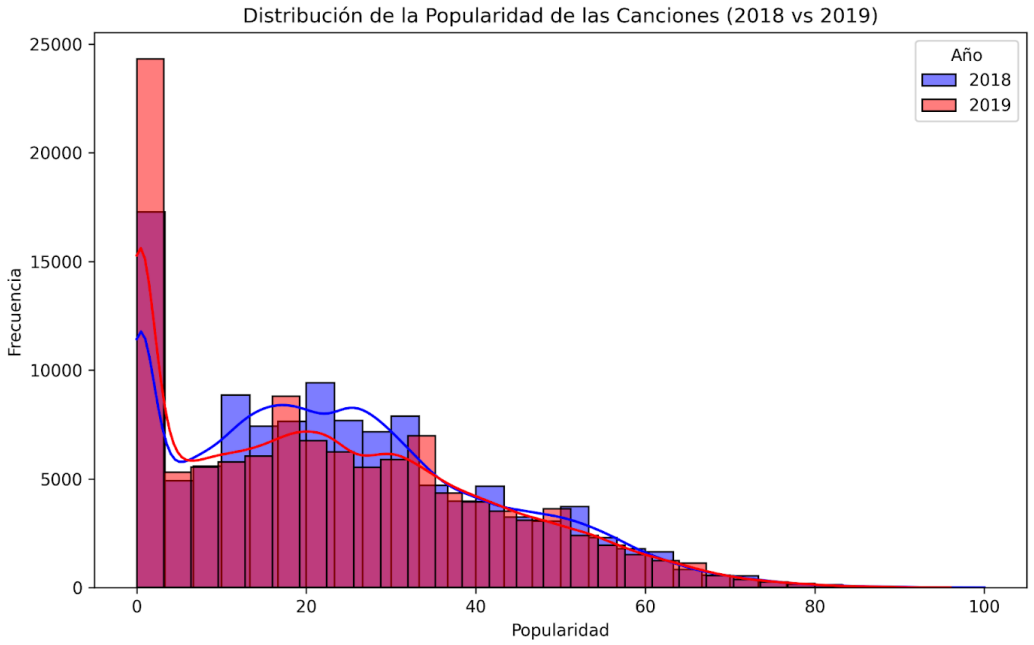
Resultados → random forest es el que mejor explica

- Base de datos
    - Partimos de dos bases de datos (una de 2018 y una de 2019) de canciones publicada en Kaggle, una vez combinadas nos quedamos con x canciones que están en ambas bases
        - Las bases fueron armadas con la API de spotify y tienen información sobre las 'features' de la canción (funcionalidad de la API que ya no funciona)
    - Como necesitamos más datos que los disponibles en esa base para nuestro análisis, utilizamos la misma API de spotify para agregar más variables a la base que nos pareció relevante
        - Por ejemplo, características del álbum y del artista
- Limpieza de datos
    - Eliminamos canciones duplicadas, tenemos 115528 observaciones
    - Eliminamos canciones que no tenían fecha de publicación (ya que fueron eliminadas de spotify)
    - Revisamos el formato de los datos
    - Revisamos que no hayan missing values (agregar heatmap)
    - Creamos dos variables
        - Calculamos promedio de seguidores
        - Calculamos promedio de popularidad de artistas
- Características de la base al final
    - Tenemos (x) observaciones, con 32326 artistas principales
    - En total, aparecen 47959 artistas, contando los featured artists
- Variables más relevantes
    - Popularity score 2025
    -
- Representación gráfica de los datos
    - no se :)

Idea 1: Power Law Distribution

➔ **Motivación**: la popularidad de las canciones en Spotify presenta una cola larga, pocas canciones concentran muchas reproducciones, mientras la gran mayoría recibe muy pocas. Estudiar esta dinámica con leyes de potencia permite cuantificar la desigualdad en la atención de los oyentes y abrir ventanas al análisis de fenómenos extremos (los llamados super hits).

- ◆ Como podemos ver en la figura, los scores de popularidad 2018-2019 siguen esa distribución.



➔ La metodología que se podría usar es máxima verosimilitud (MLE), ya que está menos sesgado que la simple regresión log-log y permite estimar correctamente α incluso en colas muy pesadas.

- ◆ $P(X \geq x) = \left(\frac{x}{x_{min}}\right)^{-\alpha+1}$, la probabilidad de observar un score mayor o igual a x decae como una potencia, con colas pesadas que hacen posible la aparición de 'super hits'.

➔ **Preguntas de interés**:

- ◆ ¿Cuál es el exponente de la cola (α) y el umbral mínimo para esa ley?
- ◆ ¿Con qué probabilidad una canción supera umbrales altos (por ejemplo, top 1 %) según la función de supervivencia teórica?

Idea 2: Análisis Exploratorio

- ➔ **Motivación**: buscamos entender cómo los audio features (danceability, energy, valence, etc) se distribuyen y varían entre canciones de distinto nivel de éxito. Esto aporta intuición previa a cualquier modelo predictivo y detecta patrones no lineales o agrupamientos de perfiles musicales.
- ➔ Puede utilizarse la información de la base de datos para agrupar canciones mediante diversas características.
- ➔ La metodología que podría utilizarse incluye:
  - ◆ Componentes principales (PCA): reducir dimensionalidad de las 12 audio features a 2–3 componentes, permite sintetizar la información multivariante.
  - ◆ Clustering no supervisado (K-Means): detecta segmentos de canciones (géneros o estilos) sin imponer categorías a priori.
  - ◆ Correlación y dependencia: matriz de correlación con heatmap.
    - Scatterplots y pairplots para pares de features que muestren dependencias fuertes o no lineales.
    - La combinación de correlación y visualizaciones multivariadas aporta intuición para el modelado predictivo.
- ➔ Queremos buscar la distribución y dispersión de cada feature (varianza, curtosis), la existencia de clusters que reflejen perfiles sonoros distintos y las correlaciones y posibles variables redundantes.
- ➔ **Preguntas de interés**:
  - ◆ ¿Cómo se distribuyen las audio features en el conjunto completo y en subgrupos de alta o baja popularidad?
  - ◆ ¿Existen clusters de canciones con perfiles acústicos similares? ¿Cómo se relacionan con la popularidad histórica?
  - ◆ ¿Qué correlaciones o dependencias detectables (lineales o no) existen entre pares de características y popularidad?

Idea 3: Análisis Predictivo

- ➔ **Motivación**: se busca construir un modelo de regresión supervisada que estime directamente el popularity score de 2025 de cada canción a partir de sus audio features y metadatos. Esto permite no sólo clasificar éxitos, sino predecir el valor continuo de popularidad para nuevos lanzamientos.
- ➔ El modelo que se considera mejor para predecir el popularity score es Random Forest Regressor.
    - ◆ Pareek et al. (2022), Dimolitsas et al. (2023) y Saragih (2023) comparan Random Forest con otros modelos y encuentran que Random Forest tiene la mayor accuracy.
- ➔ Las ventajas de Random Forest Regressor son:
    - ◆ Reducción de varianza sin incremento de sesgo significativo.
    - ◆ Captura de interacciones no lineales y de jerarquías de condiciones sin necesidad de especificar funciones base.
    - ◆ Importancias de variable derivadas de la disminución de impureza media, facilitando la interpretación.
- ➔ La diferencia de nuestro modelo con todos los anteriores es que se consideran predictores no incluidos en los otros modelos, en su mayoría los otros modelos utilizan sólo características de las canciones (las audio features). El modelo con solo audio features ya explica mucho, lo que indica una fuerte importancia de la música en sí. Si la incorporación de variables sociales sube drásticamente el R^2, sugiere que el éxito depende más de exposición y marketing que de la propia música.
- ➔ **Preguntas de interés**:
    - ◆ ¿Con qué precisión podemos predecir la popularidad en 2025? Calcular R^2 y medidas como MSE y RMSE.
    - ◆ ¿Qué variables (acousticness, danceability, energy, duración, seguidores del artista, etc.) tienen mayor importancia para explicar la varianza del popularity score 2025?
    - ◆ ¿Hasta qué punto el éxito musical es verdaderamente explicable por variables observables?

Idea 4: Análisis de Longevidad

- ➔ **Motivación**: más allá de los hits instantáneos, interesa medir cuánto tiempo permanece una canción dentro de niveles altos de popularidad y qué factores extienden ese ciclo de vida.
- ➔ Usando que nuestra base de datos tiene dos variables de popularidad histórica (de 2018 y 2019), la popularidad actual (2025) y la edad de la canción, es posible estudiar la durabilidad de las canciones en el tiempo.
  - ◆ Sería interesante calcular cómo y cuánto baja la popularidad de las canciones en el tiempo.
- ➔ **Preguntas de interés**:
  - ◆ ¿Cuál es el tiempo medio que tarda una canción en caer por debajo de un umbral de popularidad?
  - ◆ ¿Cómo influyen atributos como valence, tempo o la presencia de featured artists en la vida útil de la canción?
  - ◆ ¿Cómo afectan las audio features y los artistas colaboradores (cantidad de artistas, popularidad promedio de todos vs popularidad del artista principal) en la caída en popularidad?
  - ◆ ¿Existen diferencias de longevidad entre tipos de canciones o tipos de álbum (single vs. álbum completo)?

Bibliografía

Dimolitsas, I., Kantarelis, S., Fouka, A. (2023). *SpotHitPy: A Study For ML-Based Song Hit Prediction Using Spotify.* Cornell University.

Pareek, S., Goswami, S., Tiwari, D. (2022). *Predicting Music Popularity Using Machine Learning Algorithm and Music Metrics Available in Spotify*. International Journal of Computer Applications, 184(12), 17–24.

Saragih, H. S. (2023). *Predicting song popularity based on Spotify's audio features: insights from the Indonesian streaming users*. Journal of Management Analytics, 10:4, 693-709.

Idea General

➔ Calcular el α del popularity score usando MLE y compararlo a los resultados obtenidos entrenando un modelo con Random Forest de estar en el top 1%

- ◆ Si estos resultados son similares, esto significa que el modelo aprendió no solo los valores medios, sino la estructura desigual de la distribución
- ◆ Si hay una gran diferencia, indica que el modelo predice mal los extremos, y que no logra reproducir la dinámica real de la popularidad

Preguntas de Investigación

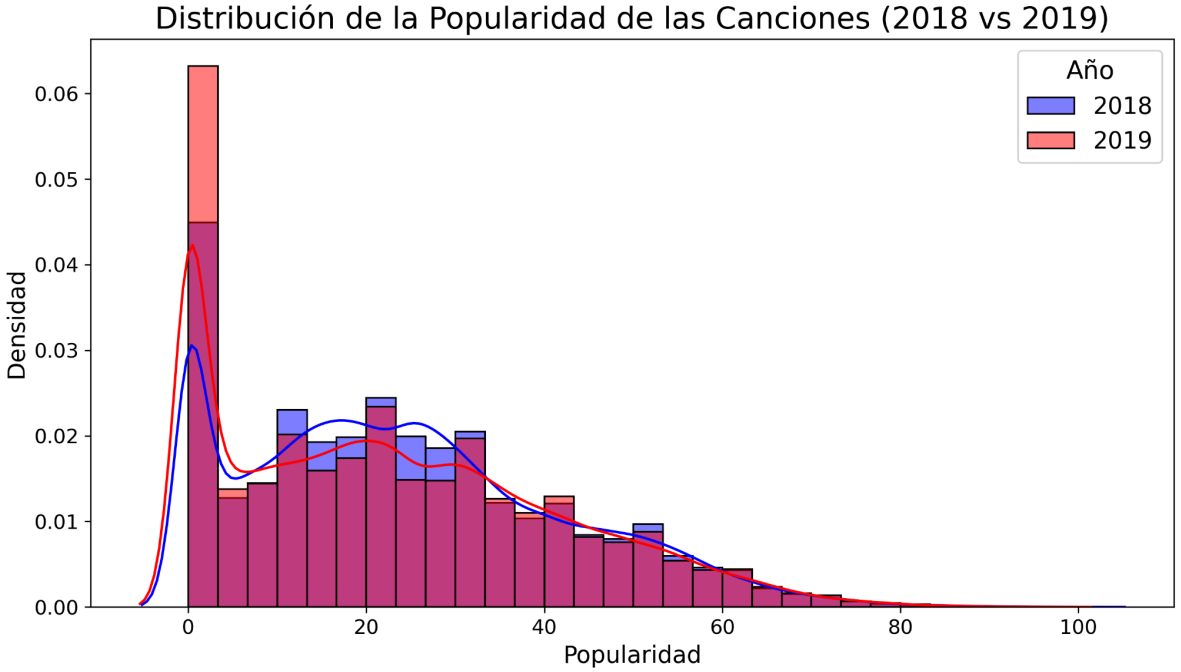
¿Con qué probabilidad una canción supera umbrales altos (por ejemplo, top 1 %) según la función de supervivencia teórica de una distribución power law, y cuánto de esa estructura de cola logra capturar un modelo de Random Forest?

- ¿Cuán diferente es la predicción de **alta popularidad en una canción** por estimación tradicional de power law vs. Random Forest?

Datos

➔ Canciones 2018 - 2019

➔ agregar estadística descriptiva de las bases (mean, std error)



Nota: El popularity score calculado por Spotify va de 0 (menos popular) a 100 (más popular).

Metodología

- ➔ Estimamos probabilidad de estar en el 1% de las canciones usando MLE
  - ◆ Paquete powerlaw en python, calcula el $\widehat{\alpha_{PL}}$ y x_{min}
  - ◆ $P(X \geq x) = \left(\frac{x}{x_{min}}\right)^{-\alpha+1}$
- ➔ Entrenamos el modelo Random Forest considerando los audio features, calculamos la probabilidad de estar en el 1%
- ➔ Usar BAYES

Resultados

Conclusión

Base de datos

https://www.kaggle.com/datasets/tomigelo/spotify-audio-features/data

Alternativas

https://www.kaggle.com/datasets/joebeachcapital/30000-spotify-songs/data

https://www.kaggle.com/datasets/saurabhshahane/spotgen-music-dataset

https://huggingface.co/datasets/maharshipandya/spotify-tracks-dataset

https://www.kaggle.com/datasets/nelgiriyewithana/top-spotify-songs-2023/data

Bibliografía

https://arxiv.org/abs/2301.07978
https://www.cdes.org.in/wp-content/uploads/2022/01/Predicting-Music-Popularity.pdf
https://www.tandfonline.com/doi/full/10.1080/23270012.2023.2239824

Power Law

https://arxiv.org/pdf/0706.1062

Buenos días, somos Catalina Gallardo y Manuel Elorga, y nuestro trabajo se titula:

"¿Cómo predecir un super hit? Un análisis comparativo de modelos de popularidad".

En los últimos años, la industria musical ha experimentado una fuerte transformación debido al crecimiento exponencial de plataformas digitales como Spotify. En este contexto, observamos una marcada concentración del consumo, en donde sólo un pequeño porcentaje de canciones logra niveles extremadamente altos de popularidad, mientras que la mayoría permanece prácticamente invisible. Esta distribución altamente sesgada plantea una pregunta central:

> ¿Qué métodos resultan más efectivos para identificar aquellas canciones que alcanzarán el éxito extremo, es decir, que estarán en el top 1% de popularidad?

Para responder esto, planteamos un análisis comparativo entre dos métodos complementarios:

En primer lugar, implementamos un modelo basado en la distribución Power Law. Mediante un estimador de máxima verosimilitud, ajustamos esta distribución debido a su característica cola larga y su alta concentración de valores extremos. El enfoque Power Law nos permite detectar canciones potencialmente populares basándonos únicamente en la estructura estadística de los datos históricos, sin considerar atributos específicos de cada canción.

En segundo lugar, aplicamos un modelo predictivo utilizando un algoritmo de aprendizaje automático, específicamente un Random Forest Classifier. Este modelo aprovecha diversas características acústicas de las canciones —tales como *acousticness*, *danceability*, *energy*, entre otras— con el objetivo de predecir individualmente qué canciones entrarán en la categoría de altísima popularidad. Este método es especialmente robusto frente a sesgos y relaciones no lineales entre variables.

La comparación entre estos dos enfoques reveló resultados interesantes:

- El modelo basado en la distribución Power Law identificó una mayor proporción de canciones del top 1%, demostrando ser altamente sensible. Sin embargo, esta mayor capacidad de detección vino acompañada por una tasa elevada de falsos positivos, es decir, canciones que fueron clasificadas como altamente populares pero que, en realidad, no lo eran.

- Por otro lado, el modelo Random Forest mostró una precisión significativamente superior. Aunque identificó una cantidad algo menor de hits potenciales, sus predicciones fueron mucho más fiables, con menos falsos positivos y mayor exactitud global en las clasificaciones positivas.

Estos resultados ponen de manifiesto la complementariedad entre ambos métodos. La aproximación Power Law ofrece un diagnóstico general sobre la estructura desigual del

mercado, ideal para un análisis macro de la popularidad. En cambio, el Random Forest permite realizar predicciones específicas basadas en las propiedades concretas de las canciones, ofreciendo un análisis micro más preciso.

En conclusión, este estudio no sólo ayuda a entender mejor cómo funciona el mercado musical en plataformas digitales, sino que también proporciona herramientas útiles para artistas, productores y plataformas interesadas en optimizar estrategias de lanzamiento y recomendación musical.

Tabla de resultados

Accuracy mide la proporción global de predicciones correctas sobre el total analizado. En nuestros resultados observamos que el modelo Random Forest obtiene un accuracy más alto, lo cual indica que globalmente es más eficaz clasificando canciones tanto populares como no populares. Esto se debe a que el algoritmo captura mejor las relaciones complejas y no lineales presentes en los datos acústicos, reduciendo la cantidad total de errores en sus predicciones.

Precision evalúa cuántas de las canciones clasificadas como altamente populares realmente pertenecen al top 1%. Nuestro modelo Random Forest también mostró mayor precision, indicando que cuando este modelo clasifica una canción como popular, la probabilidad de estar en lo correcto es alta. Por el contrario, el modelo basado en Power Law, al depender únicamente de la estructura estadística global y no de atributos individuales, tiende a producir más falsos positivos, disminuyendo su precision.

Recall, por otra parte, indica qué proporción de las canciones verdaderamente populares fueron correctamente identificadas. El modelo basado en Power Law mostró un valor de recall más alto, lo que significa que detectó un número mayor de hits reales, aunque esto vino acompañado de un mayor número de errores tipo falso positivo. Esto es esperable teóricamente dado que el enfoque Power Law “apuesta” amplio y no individualiza características, favoreciendo la detección de potenciales hits pero con menos discriminación.

F1-Score equilibra precision y recall en una sola métrica armónica, refleja cuán balanceado es el modelo. El modelo de Random Forest presentó un mayor F1-Score, mostrando que logra un equilibrio superior entre no equivocarse demasiado (alta precision) y no dejar pasar demasiados éxitos reales (alto recall relativo). Esto fundamenta que, en términos generales, el Random Forest es más robusto como modelo predictivo, combinando eficacia global y precisión individual en sus clasificaciones.

AUC evalúa la capacidad discriminativa del modelo: mide qué tan bien puede distinguir entre canciones populares y no populares a través de distintos umbrales de decisión. Un AUC más alto en el modelo de Random Forest refleja una mayor capacidad para separar ambos grupos, lo que refuerza su superioridad como clasificador en términos globales. Es una métrica especialmente relevante cuando las clases están desbalanceadas, como es el caso de nuestro dataset (donde sólo el 1% es popular).

Por último, incorporamos MSE (Mean Squared Error) como medida del error cuadrático medio entre la probabilidad predicha y la clase real (popular o no popular, codificada como 1 o 0). Un MSE menor en Random Forest indica que sus predicciones probabilísticas están, en promedio, más cerca de la realidad, incluso cuando no se toma una decisión de corte.

Matrices de confusión

Para complementar las métricas promedio, analizamos las matrices de confusión de ambos modelos. Esta herramienta nos permite examinar con mayor detalle la lógica con la que cada modelo toma decisiones, diferenciando entre aciertos y errores en cada clase.

En primer lugar, observamos que el modelo basado en Power Law presenta una alta cantidad de verdaderos positivos, es decir, identifica correctamente muchas de las canciones que realmente pertenecen al top 1% de popularidad. Esto se traduce en un recall elevado, lo que implica que el modelo logra capturar una gran parte de los éxitos reales.

Sin embargo, este buen desempeño en términos de cobertura viene acompañado por una gran cantidad de falsos positivos: muchas canciones que no son populares son clasificadas erróneamente como si lo fueran. Esto afecta directamente su precisión, disminuyendo su fiabilidad como herramienta de predicción específica. En términos prácticos, el modelo Power Law presenta un enfoque de tipo “apuesta amplia”, priorizando no dejar escapar posibles éxitos, aunque al costo de generar numerosas falsas alarmas.

Por el contrario, la matriz de confusión del modelo Random Forest muestra un perfil diferente: si bien detecta una menor cantidad de hits en términos absolutos, comete significativamente menos errores de clasificación. Esto se refleja en una alta precisión y un mejor equilibrio general entre verdaderos positivos y negativos. El modelo logra mantener bajos los falsos positivos y también reduce los falsos negativos, aunque en menor proporción que el Power Law.

Este comportamiento se alinea con la lógica interna del Random Forest, que prioriza la calidad de la predicción individual a través del análisis conjunto de múltiples atributos acústicos. En consecuencia, cuando el Random Forest predice que una canción será exitosa, hay una alta probabilidad de que esté en lo correcto. Esto lo convierte en un modelo más confiable para aplicaciones donde es importante minimizar errores, como la recomendación musical o la asignación de recursos promocionales.