UNIVERSIDAD DE SAN ANDRÉS

BIG DATA

OTOÑO 2025

TRABAJO PRÁCTICO N°1

UN PRIMER ENCUENTRO CON LA EPH

Fecha de entrega: martes 25 de marzo a las 23:59hs.

Contenido*:* familiarización con la base de datos de la Encuesta Permanente de Hogares. Limpieza de datos, valores faltantes y análisis descriptivo.

Modalidad de entrega

- El informe debe subirse al Campus Virtual en formato PDF con el nombre **Big_Data_TP1_Grupo#**.pdf (donde **#** es el número de grupo), incluyendo gráficos e imágenes dentro del mismo archivo. La extensión máxima es de 8 páginas (sin apéndices) y se espera una redacción clara y precisa.

- Se debe publicar en el repositorio de GitHub de cada grupo el código con los comandos utilizados, indicando claramente a qué inciso corresponde cada uno. El nombre del archivo deberá ser **Big_Data_TP1_Grupo#**.

- **Cualquier detección de copia o plagio será sancionada.**

Parte I: Familiarizandonos con la base EPH

La Encuesta Permanente de Hogares (EPH) es un programa nacional de producción sistemática y permanente de indicadores sociales que lleva a cabo el Instituto Nacional de Estadística y Censos (INDEC), que permite conocer las características sociodemográficas y socioeconómicas de la población. Uno de los indicadores más valiosos sobre el mercado laboral que pueden obtenerse con los datos de esta encuesta es la tasa de desocupación.

1. Utilizando información disponible en la página del INDEC, expliquen brevemente cómo se identifica a las personas desocupadas.

2. Entren a la página https://www.indec.gob.ar/ y vayan a la sección *Servicios y Herramientas → Bases de datos*. Descarguen la base de microdatos de la Encuesta Permanente de Hogares (EPH) correspondiente al primer trimestre de **2004** y **2024** en formato .dta y .xls, respectivamente (una vez descargadas, las bases a usar deberán llamarse `usu_individual_T104.dta` y `usu_individual_T124.xls`). En la página web, también encontrará un diccionario de variables con el nombre de "Diseño de registro y estructura para las bases preliminares (hogares y personas)". Descarguen el diccionario de cada año. En estos archivos se les indica qué significa cada variable que aparece en la base de datos, en particular, en la sección de Diseño de registros de la base Personas.

    a. A partir de ahora, cada grupo trabajará con una región del país en específico. En la Tabla (1), encontrarán la región asignada a cada grupo. Eliminen los datos de todas aquellas provincias que no se encuentren dentro de su región y unan ambos trimestres en una sola base.[1]

    b. Antes de arrancar con la limpieza de la base, cree un *heatmap* mostrando valores faltantes de las diez (10) variables que más les llamó la atención de la EPH.

    c. Si encuentran observaciones con valores que no tienen sentido (por ejemplo, ingresos negativos o edades negativas), asígnenles valores faltantes (missing values). Se espera que piensen en otros casos de valores sin sentido, no únicamente los mencionados en los ejemplos. Expliquen **detalladamente** cada decisión que tomen.

    d. Hagan una limpieza profunda de las bases de datos. Asegúrense de que todas las variables tengan el formato

[1] *Hint*: Note el tipo de variables (string vs. byte or float) entre las dos bases de datos de 2004 y 2024. Deberán unificar todo con un solo tipo de variables.

correcto. Comenten todos los cambios hechos para lograr una base limpia y ordenada.

e. Una vez hecha la limpieza, hagan un *heatmap* mostrando los valores faltantes de las variables de las diez (10) variables que eligieron en el inciso b. Ahora tiene un *heatmap antes* y *después* de la limpieza ¿Observan algún patrón interesante? ¿Alguna de sus variables de interés presenta muchos NAs?

Parte II: Primer Análisis Exploratorio

3. Realicen un gráfico de barras mostrando la composición por sexo para 2004 y 2024. Comenten los resultados.

4. Realicen una matriz de correlación para 2004 y 2024 con las siguientes variables: `CH04`, `CH06`, `CH07`, `CH08`, `NIVEL ED`, `ESTADO`, `CAT_INAC`, `IPCF`. Utilicen alguno de los comandos disponibles en este link o este link para graficar la matriz de correlación. Comenten los resultados.[2]

Parte III: Conociendo a los ocupados y desocupados

5. ¿Cuántos desocupados hay en la muestra? ¿Cuántos inactivos? ¿Cuál es la media de ingreso per cápita familiar (IPCF) según estado (ocupado, desocupado, inactivo)?

6. Uno de los grandes problemas de la EPH es la creciente cantidad de hogares que no reportan sus ingresos (ver por ejemplo el siguiente informe). ¿Cuántas personas no respondieron cuál es su condición de actividad? Guarden como una base distinta llamada `respondieron` las observaciones donde respondieron la pregunta sobre su condición de actividad (`ESTADO`). Las observaciones con `ESTADO=0` guárdenlas en una base bajo el nombre `norespondieron`.

7. Agreguen a la base `respondieron` una columna llamada "PEA" (Población Económicamente Activa) que tome 1 si están ocupados o desocupados en `ESTADO`. Realicen un gráfico de barras mostrando la composición por PEA para 2004 y 2024. Comenten los resultados.

8. Agreguen a la base `respondieron` una columna llamada "PET" (Población en Edad para Trabajar) que tome 1 si están la persona tiene entre 15 y 65 años cumplidos. Realicen un gráfico de barras mostrando la composición por PEA para 2004 y 2024. Comenten los resultados y comparen PET con PEA.

---

[2] Para todos los gráficos que presenten, recuerde tener presentes los tres principios de visualización de datos discutidos en la Clase 1. Referencia: † Schwabish, J. A. (2014). An economist's guide to visualizing data. *Journal of Economic Perspectives*, 28(1), 209-234.

9. Agreguen a la base `respondieron` una columna llamada "desocupado" que tome 1 si la persona está desocupada. ¿Cuántas personas están desocupadas en 2004 vs 2024?

    a. Muestre la proporción de desocupados por nivel educativo comparando 2004 vs 2024. ¿Hubo cambios de desocupados por nivel educativo?

    b. Cree una variable categórica de años cumplidos (`CH06`) agrupada de a 10 años. Muestre proporción de desocupados por edad agrupada comparando 2004 vs 2024. ¿Hubo cambios de desocupados por edad?

    c. Seleccione **una (1)** variable de interés y muestre las diferencias 2004 vs 2024. ¿Hubo cambios de desocupados por edad?

10. *Dos tasas de desocupación*: calculen la tasa de desocupación para su región en 2004 y 2024 siguiendo la definición del INDEC. En economía laboral, muchas veces se argumenta que participar del mercado laboral (PEA=1) es una decisión endógena de los individuos y no quisiéramos que el indicador de la tasa de desocupación varíe por dicha decisión. Calcule la tasa de desocupación alternativa como el porcentaje de desocupados respecto de la PET. Presente en una tabla o gráfico la tasa de desocupación del INDEC y de economía laboral para 2004 y 2024 y comente los resultados. ¿Cuáles son las ventajas y desventajas de dichas mediciones?

Tabla 1: Regiones y provincias por grupo

Grupo	Región	Provincias
1	Gran BA	CABA & GBA
2	NOA 1	La Rioja, Tucumán & Catamarca
3	NOA 2	Jujuy, Salta & Santiago del Estero
4	NEA	Posadas, Resistencia, Corrientes & Formosa
5	Cuyo	Mendoza, San Juan, San Luis
6	Pampeana 1	La Plata, Bahía Blanca, Mar del Plata
7	Pampeana 2	Gran Rosario, Gran Santa Fe & Gran Paraná, Concordia
8	Pampeana 2	Gran Córdoba, Río Cuarto, Santa Rosa - Toay
9	Patagonia	Cdro. Rivadavia – Rada Tilly, Neuquén, Río Gallegos, Ushuaia