

Trabajo Practico Nº1

(Semestre de Otoño 2025)

Big Data

Profesora: María Noelia Romero
Tutor: Tomás Pacheco
Alumnos: Catalina Gallardo, Manuel Elorga

PARTE 1: Familiarizandonos con la base EPH

Ejercicio 1

El INDEC para identificar si una persona está desocupada aplica tres elementos fundamentales. La primera es no haber desarrollado ningún tipo de actividad económica que sea remunerada. Segundo, debe haber realizado acciones concretas para obtener trabajo en los últimos 30 días como enviar curriculums, registrarse en agencias de empleo, etc. Finalmente, debe estar disponible para incorporarse a un empleo en caso de recibir una oferta. El INDEC diferencia entre tres grupos dentro del mercado de trabajo: la población ocupada, desocupada y inactiva. La población ocupada está compuesta por aquellas personas que han trabajado al menos una hora en la semana, ya sea de manera remunerada o sin remuneración. Por otro lado, la población inactiva está conformada por aquellas personas que no tienen empleo y que no están buscando trabajo de manera activa como estudiantes, jubilados y personas dedicadas a tareas del hogar. Dentro de la población económicamente activa se encuentran tanto las personas ocupadas como los desocupados.

La tasa de desocupación se calcula como el porcentaje de la población desocupada sobre la población económicamente activa. Este indicador permite evaluar la evolución del mercado laboral ya que da a conocer la cantidad de personas que desean trabajar pero no encuentran empleo.

El análisis de la desocupación es fundamental para comprender la dinámica del mercado de trabajo y evaluar el impacto de las políticas económicas y sociales. Una tasa de desocupación elevada puede reflejar problemas como la falta de oportunidades laborales en diferentes sectores, crisis económicas que afectan la demanda de empleo, etc.

Ejercicio 2

Inciso b

Para el heatmap de valores faltantes, elegimos las siguientes 10 variables:

- **CH14**: Último año de educación aprobado.
- **CH15_COD**: Código correspondiente al lugar de nacimiento (provincia o país extranjero).
- **CH16_COD**: Código correspondiente al lugar de residencia hace 5 años (provincia o país extranjero).
- **PP03C**: Número de empleos o actividades laborales desempeñadas en la última semana.
- **PP03I**: Búsqueda de trabajo adicional en los últimos 30 días.
- **PP04B_COD**: Código de la actividad económica de la empresa o institución en la que trabaja.

- **PP06H**: Indica si la actividad es un negocio familiar.
- **PP07A**: Tiempo continuo trabajado en el empleo actual.
- **PP10A**: Tiempo de búsqueda de empleo en personas desocupadas.
- **PP11A**: Sector (estatal, privado u otro) del último empleo de los desocupados con trabajo anterior.

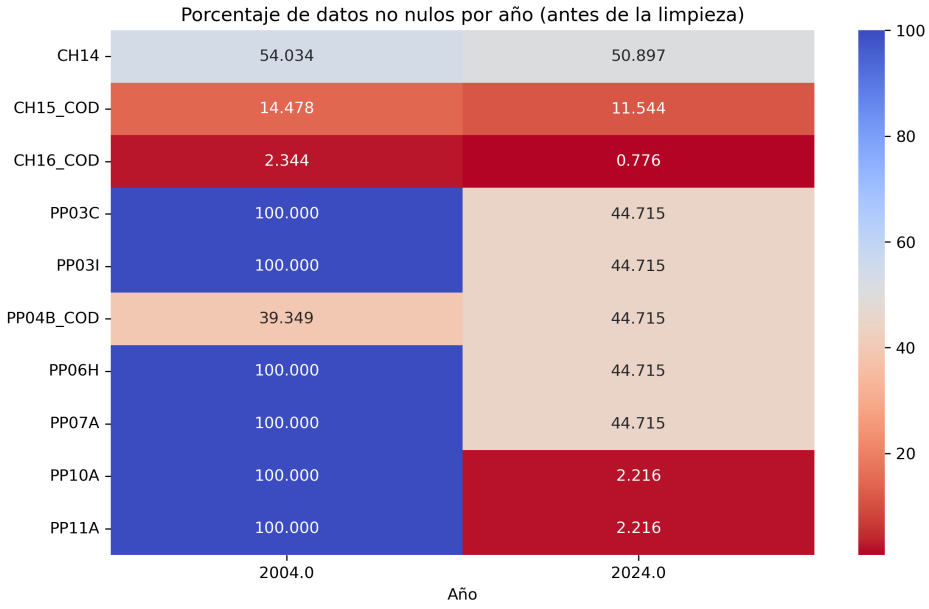


Figura 1: Heatmap de missing values, antes de la limpieza

La figura 1 muestra que faltan bastantes datos sobre el último año aprobado, tanto para 2004 como para 2024. Además, vemos una gran cantidad de valores faltantes en las variables de codigo de lugar de nacimiento, residencia y acttividad económica. Por último, se reportan muchos missing values también en preguntas realizas únicamente a personas ocupadas o desocupadas en el 2024. Esto no era un problema en 2004, lo que da a pensar que puede haber diferencias en como se cargan los datos.

Inciso c

Eliminamos las siguientes observaciones sin sentido:

- En la columna **CH06** (edad), existían observaciones con el valor -1, que deberían representar "Menor de 1". Se convirtieron a 0.
- En la columna **CH14** (último año aprobado), en la base de datos del año 2004, aparecían valores incorrectos (98), los cuales fueron remplazados por valores nulos. Para 2024, el 98 significa ."Educación especial".

- En la columna **PP06C** (ingresos), se encontraron valores negativos distintos de -9 (que indica "No sabe/No contesta"). Los valores -7 y -8 fueron reemplazados por valores nulos.
- En la columna **PP06D** (ingresos), al igual que en **PP06C**, se eliminaron los valores negativos distintos de -9, convirtiendo -7 y -8 en valores nulos.

Fuera de esos reemplazos, se verificó que todas las columnas tuvieran todos los valores en el rango de respuestas validas. Se verificó que la cantidad de horas trabajadas en la última semana no exceda las 168 horas (horas en una semana), entro otros controles.

Inciso d

Para limpiar la base de datos, se realizaron los siguientes cambios:

- Se eliminaron las columnas que existían solo en una de las bases de datos fusionadas para garantizar uniformidad.
- Se transformó la variable **MAS_500** en binaria, asignando 1 si el aglomerado tiene más de 500.000 habitantes y 0 en caso contrario.
- Se estableció que si la persona es menor de dos años (**CH09** = 3) o nunca asistió a un establecimiento educativo (**CH10** = 3), entonces es posible afirmar que no aprobó ningún nivel educativo (**CH14** = 0), reemplazando los valores nulos.
- Se ajustaron las variables **CH15_COD** y **CH16_COD**, que solo deben tomar valores si **CH15** o **CH16** son 3, 4 o 5, asignándoles 0 en los demás casos (que interpretamos como "pregunta no aplica").
- Se ajustó **PP04B_COD** para que solo tome valores si **PP04A** es 3, reemplazando los valores nulos por 0 (que interpretamos como "pregunta no aplica").
- Se ajustó **PP06H** para que solo tome valores si **PP06E** es 2 o 3, reemplazando los valores nulos por 0 (que interpretamos como "pregunta no aplica").
- Se convirtieron en variables binarias:
  - **PP05F**, asignando 1 si el negocio trabaja con un solo cliente y 2 si trabaja con múltiples clientes.
  - **PP07F5** y **PP07G_59**, asignando 1 si la respuesta es afirmativa.
- Se reemplazaron los valores faltantes en variables que solo aplican a personas ocupadas o desocupadas con 0 si el individuo no pertenece a esa categoría, para disminuir la cantidad de valores nulos.
- Se eliminaron variables no necesarias: **IMPUTA** (sin observaciones), **PP09A**, **PP09A_ESP**, **PP09B**, **PP09C** y **PP09C_ESP** (dependientes de otras variables o aplicables solo a ciertas regiones).

- Se convirtieron a enteros las variables que deberían tener valores discretos, excluyendo montos de ingreso y la variable **CODUSU** (el codigo para distinguir viviendas).
- Se garantizó que las variables de ingreso sean de tipo floats para preservar precisión en los cálculos.

Inciso e

Luego de la limpieza de la base de datos, el heatmap de valores faltantes se ve ahora de la siguiente forma.

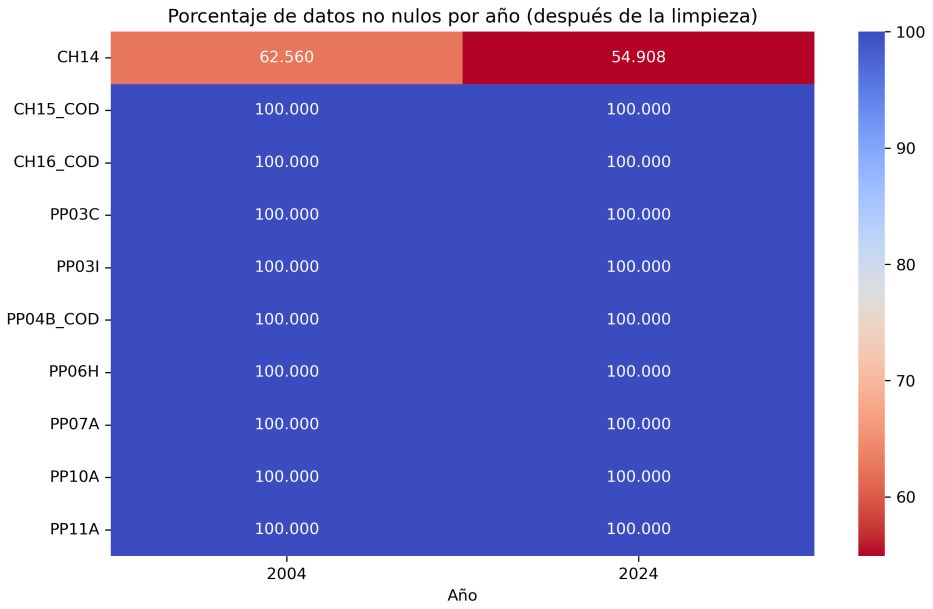


Figura 2: Heatmap de missing values, después de la limpieza

En la figura 2, vemos que con la limpieza se lograron reemplazar casi todos los missing values, con la excepción de aquellos en la columna CH14 (último año escolar aprobado). Si bien se hizo inferencia al respecto de algunas personas que no habían aprobado ningún año -como los menores de dos años, que aún no están en edad escolar, y aquellos que reportaron nunca haber asistido a una institución educativa.

PARTE II: Primer Analisis Exploratorio

Ejercicio 3

La figura 3 ilustra la comparación de la cantidad de hombres y mujeres en los años 2004 y 2024, permitiendonos observar como ha evolucionado la composición por sexo a lo largo del tiempo.

Por un lado, en 2004, los datos nos ofrecen que hubo aproximadamente 2291 hombres y 2530 mujeres, es decir, habia una diferencia de 239 personas a favor de las mujeres. Por otro lado, en 2024, se puede observar alrededor de 2143 hombres y 2370 mujeres proporcionandonos nuevamente una brecha a favor de las mujeres de 227 personas. Es necesario destacar que se presenta una leve disminución respecto a la diferencia previa. Ademas, tanto los hombres como mujeres hay una reduccion entre el año 2004 y 2024.

En definitiva, se ofrece una composición por sexo en el que se experimenta variaciones relativamente pequeñas pero significativas.

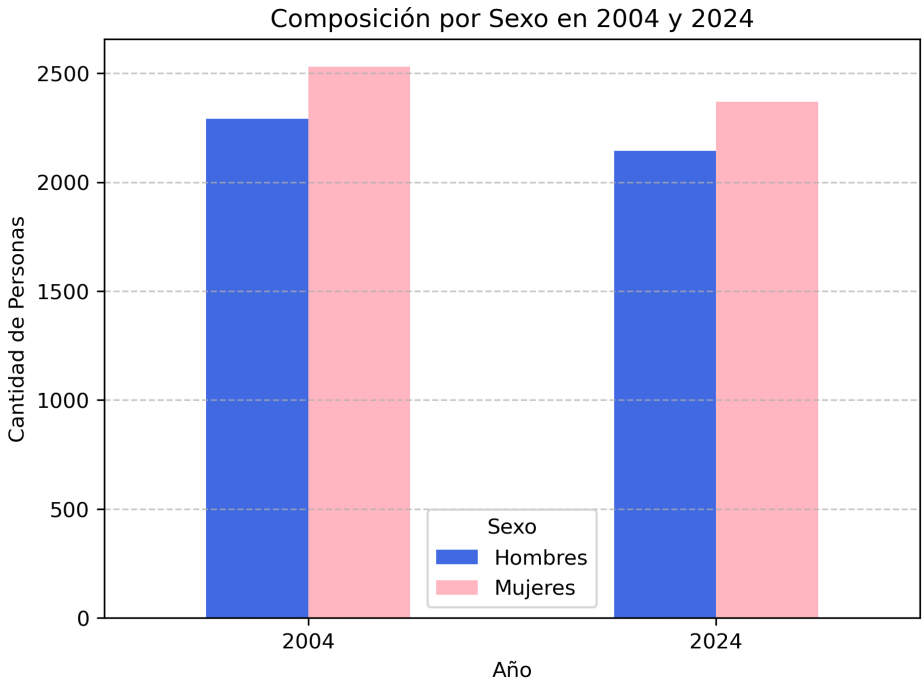


Figura 3: Composición por sexo en 2004 y 2024

Ejercicio 4

Las figuras 4 y 5 presentan matrices de correlación para los años 2004 y 2024 entre las variables CH04 (sexo), CH06 (edad), CH07 (estado conyugal), CH08 (cobertura médica), NIVEL_ED (nivel educativo), ESTADO (ocupado, desocupado, inactivo), CAT_INAC (categoría de inactividad) e IPCF (ingreso per cápita familiar). En ambos años, CH04 (sexo) muestra correlaciones bajas con el resto de las variables, indicando que ser hombre o mujer no tiene una asociación significativa con factores como la edad, el nivel educativo o el ingreso familiar. Asimismo, CH07 (estado conyugal) mantiene correlaciones débiles con otras variables, lo que sugiere que el estado civil no está fuertemente vinculado con la educación o el empleo. Por su parte, la relación entre CH06 (edad) y CAT_INAC sigue siendo positiva, lo que confirma que a medida

que aumenta la edad, la probabilidad de ser inactivo (jubilado, estudiante, etc.) también lo hace.

En relación con CH08 (cobertura médica), en ambas matrices se observa una correlación positiva con NIVEL_ED y con IPCF, lo que indica que a mayor nivel educativo y mayores ingresos, es más probable contar con cobertura médica. Sin embargo, en 2024 esta relación se ha intensificado, lo que sugiere que el acceso a la salud depende cada vez más de factores económicos y educativos. Es importante señalar que la correlación negativa que se observa en la matriz no implica una relación inversa, sino que depende de la codificación de la variable, donde valores más bajos indican una mejor cobertura. Además, la relación entre NIVEL_ED e IPCF, aunque sigue siendo positiva, ha disminuido en 2024, reflejando posibles cambios en la estructura del mercado laboral o en la accesibilidad de los ingresos para los niveles educativos más altos.

Por otro lado, ESTADO (condición de actividad) mantiene una correlación negativa con CAT_INAC, ya que una persona no puede ser activa e inactiva al mismo tiempo, y esta relación se mantiene estable en 2024. La correlación entre ESTADO e IPCF sigue siendo baja en ambos años, lo que puede explicarse porque los hogares tienen otras fuentes de ingresos además del empleo individual. Finalmente, CAT_INAC se correlaciona negativamente tanto con ESTADO como con CH06 (edad), lo que reafirma que la inactividad está estrechamente relacionada con la edad y la condición laboral. En general, las matrices reflejan cambios en la dinámica laboral y social en estas dos décadas, con una mayor dependencia del nivel educativo e ingresos para el acceso a bienes y servicios como la cobertura médica.

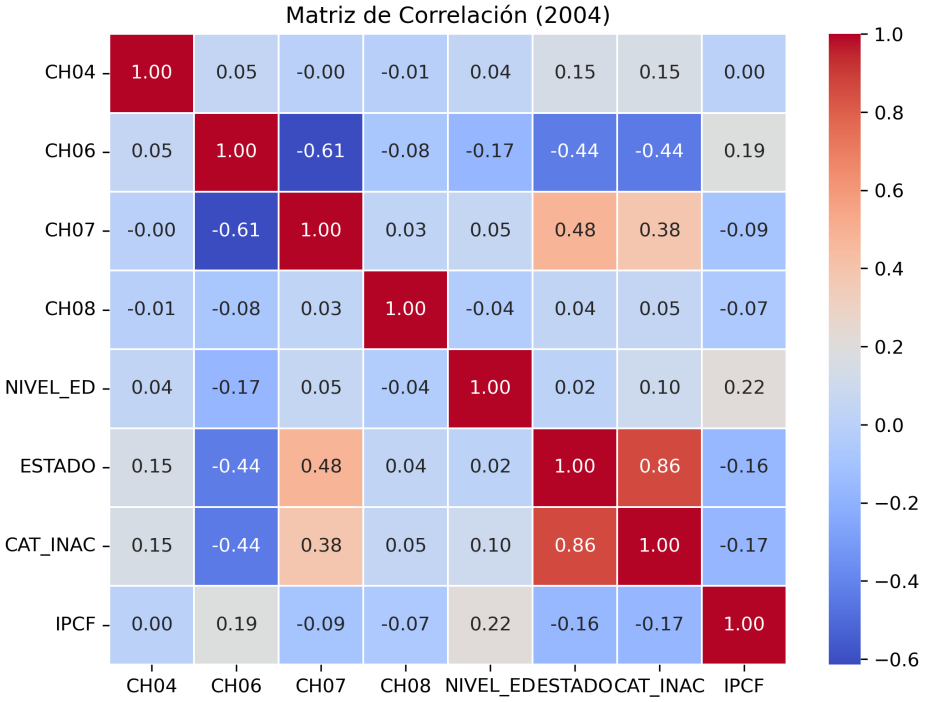


Figura 4: Matriz de correlación 2004

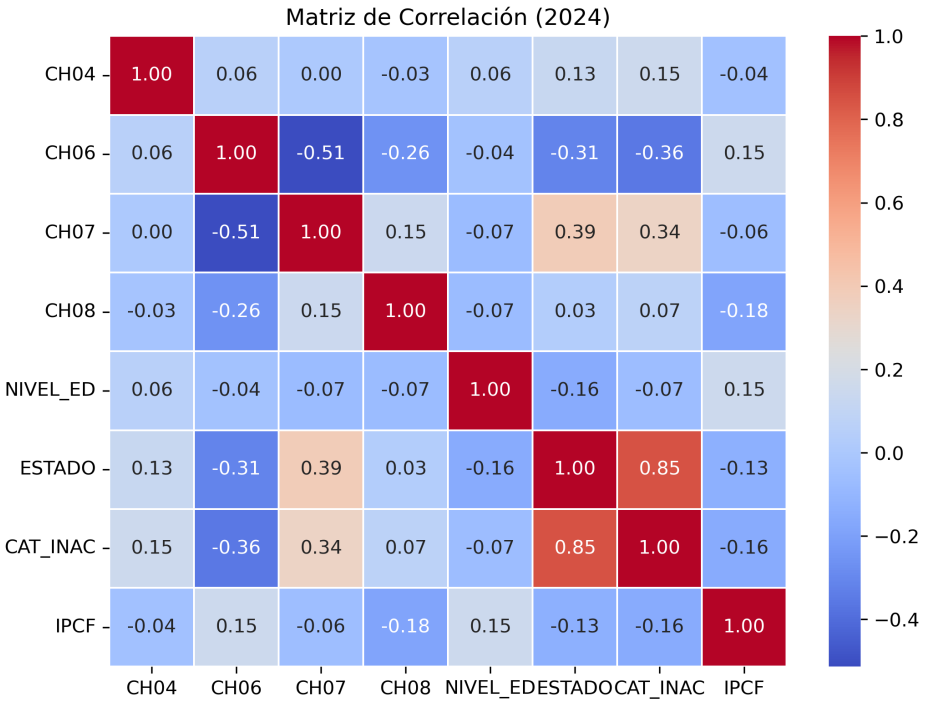


Figura 5: Matriz de correlación 2024

PARTE III: Conociendo a los ocupados y desocupados

Ejercicio 5

Hay 323 desocupados y 5090 inactivos en la muestra. La media de ingreso per cápita familiar para los ocupados es de 96894.0. La media de ingreso per cápita familiar para los desocupados es de 33435.31. La media de ingreso per cápita familiar para los inactivos es de 66566.35.

Ejercicio 6

Hay 6 personas en la muestra no respondieron sobre su condición de actividad, todos en 2024.

Ejercicio 7

La figura 6 muestra la disribución entre población económicamente activa vs no activa. Podemos ver que hay más personas no activas que activas. Esto puede deberse a la gran cantidad de niños presentes en la muestra. Se aprecia también que hay una disminución de cantidad entre 2004 y 2024.

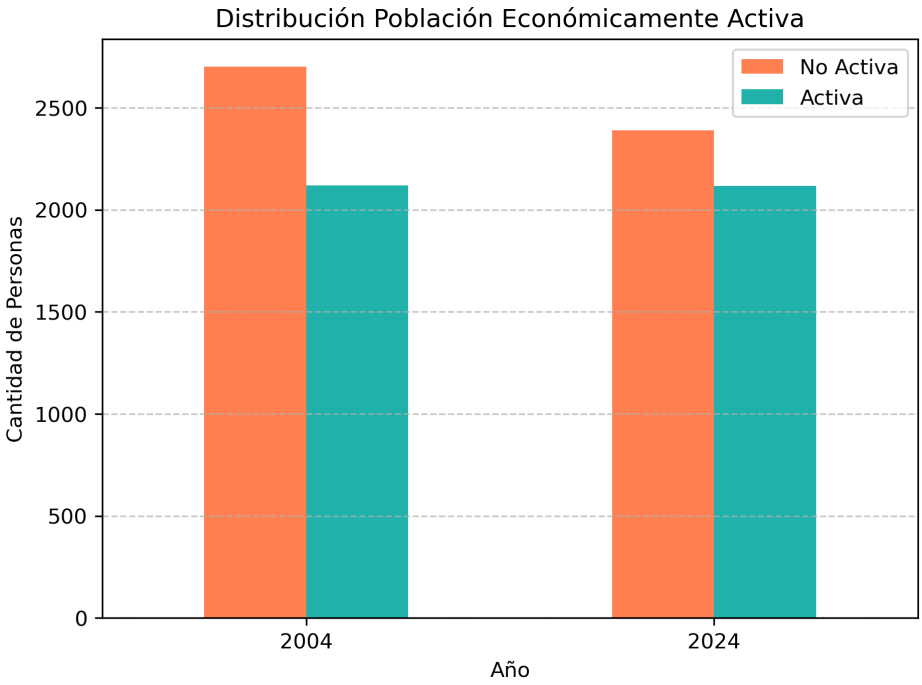


Figura 6: Composición por PEA (2004 y 2024)

Ejercicio 8

La figura 7 muestra la distribución entre personas en edad laboral vs no edad laboral. Vemos que la mayor parte de la muestra (en ambos años) están en edad laboral. Sin embargo, esto no significa que efectivamente estén ocupados (o que estén buscando trabajo). Comparando con la figura anterior, muchas personas en edad laboral no están buscando trabajo. Esto puede deberse a que sean estudiantes u otra categoria de inactividad.

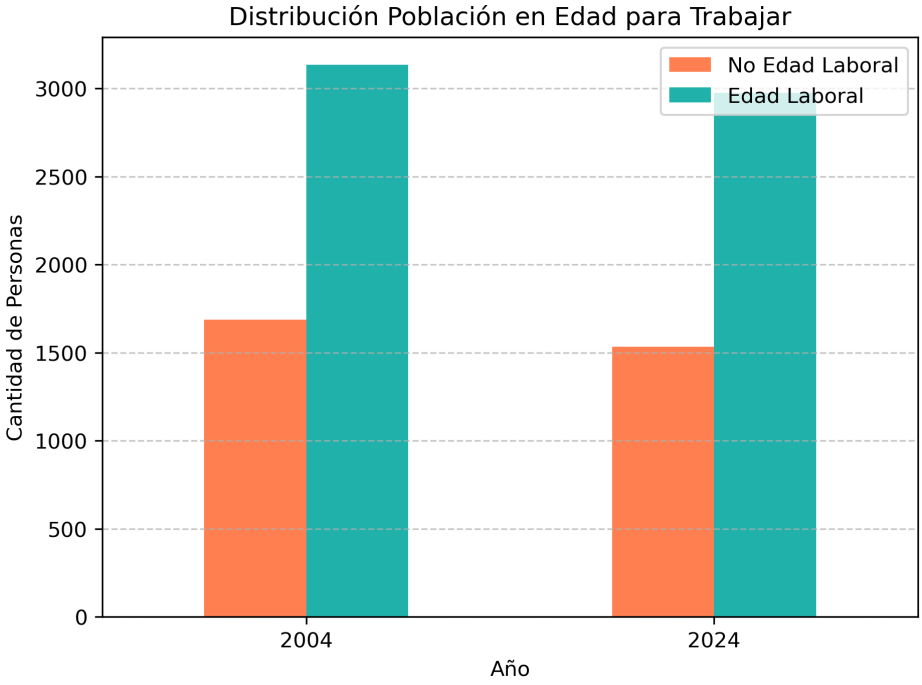


Figura 7: Composición por PET (2004 y 2024)

Ejercicio 9

En la muestra, la desocupación bajó en 2024 respecto al 2004. Hubo 223 desocupados en 2004 y 100 desocupados en 2024.

Inciso a

La figura 8 muestra las proporciones de desocupados por nivel educativo en 2004 y 2024, permite observar importantes cambios en la relación entre el nivel educativo y la desocupación a lo largo del tiempo. Para calcular esto, se conto a los desocupados de cada grupo y de dividio por la población económicamente activa del mismo, para dejar de lado personas inactivas. Un ejemplo de esto sería niños que no terminaron la primaria porque están aún en edad escolar. Los principales resultados que se encuentran son los siguientes:

- El 15.25 % de las personas económicamente activas en la muestra con nivel educativo Primaria Incompleta eran desocupados en 2024, mientras que en 2004 fueron 3.61 %.
- El 1.76 % de las personas económicamente activas en la muestra con nivel educativo Primaria Completa eran desocupados en 2024, mientras que en 2004 fueron 8.08 %.
- El 6.26 % de las personas económicamente activas en la muestra con nivel educativo Secundaria Incompleta eran desocupados en 2024, mientras que en 2004 fueron 13.79 %.
- El 4.59 % de las personas económicamente activas en la muestra con nivel educativo Secundaria Completa eran desocupados en 2024, mientras que en 2004 fueron 11.09 %.
- El 5.76 % de las personas económicamente activas en la muestra con nivel educativo Universitaria Incompleta eran desocupados en 2024, mientras que en 2004 fueron 15.86 %.
- El 2.89 % de las personas económicamente activas en la muestra con nivel educativo Universitaria Completa eran desocupados en 2024, mientras que en 2004 fueron 7.58 %.
- El 0.0 % de las personas económicamente activas en la muestra con nivel educativo Sin instrucción eran desocupados en 2024, mientras que en 2004 fueron 20.0 %. Esta gran reducción puede ser explicada principalmente por el hecho de que en 2024 solo dos personas de la muestra reportaron nivel educativo "Sin instrucción".

En general, la desocupación disminuyó en todos los niveles educativos entre 2004 y 2024, indicando un mejor panorama laboral en el tiempo. La mejora fue más notable en los niveles más altos de educación (universitaria completa e incompleta), mientras que los niveles más bajos, como primaria incompleta, mostraron un incremento en la desocupación, posiblemente debido a mayores exigencias del mercado laboral. Este análisis destaca la importancia de la educación en la inserción laboral, con una clara ventaja para quienes poseen niveles educativos más altos. Sin embargo, es importante considerar el reducido tamaño de la muestra para cada nivel.

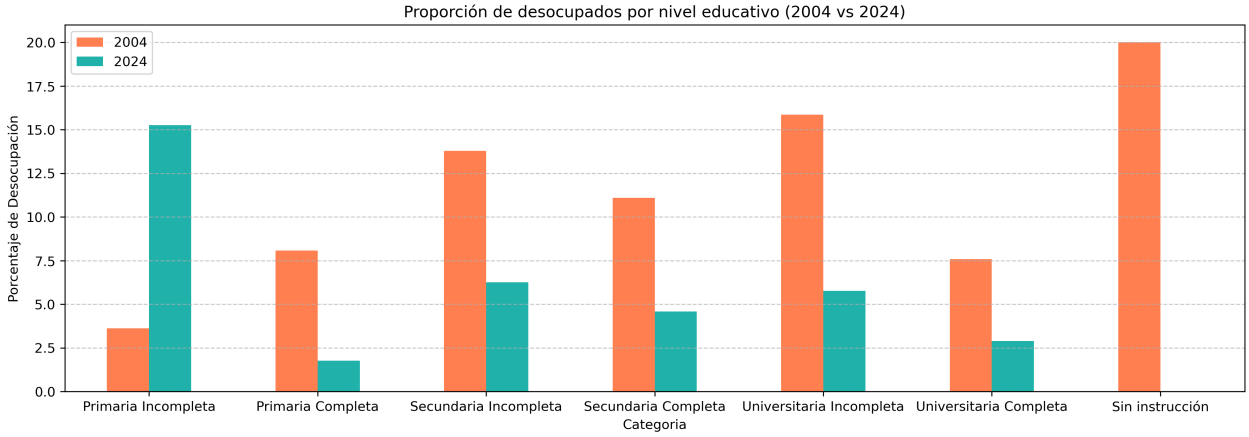


Figura 8: Distribución desocupados por nivel educativo (2004 y 2024)

Inciso b

La figura 9 compara las tasas de desocupación por grupo etario en 2004 y 2024, permite observar cómo la desocupación afecta a distintas edades y cómo estas proporciones han cambiado a lo largo del tiempo.

- **Grupos sin participación económica:** No hay personas económicamente activas en los grupos de 0 a 9 años ni de 90 a 99 años en ninguno de los dos años analizados, lo cual es consistente con las expectativas.
- **Desocupación en los jóvenes:**
  - En 2004, los jóvenes de 10 a 19 años y 20 a 29 años presentan las tasas más altas de desocupación, con valores de 19.05 % y 19.19 %, respectivamente. Esto podría deberse a la falta de experiencia laboral y a la transición de los estudios al empleo.
  - En 2024, las tasas para estos grupos disminuyen considerablemente, siendo 5.88 % para 10 a 19 años y 9.75 % para 20 a 29 años. Aunque sigue siendo relativamente alta en comparación con otros grupos, la disminución es notable.
- **Desocupación en los adultos:**
  - En 2004, los adultos entre 30 y 49 años presentan tasas moderadas de desocupación (7.23 % para 30 a 39 años y 7.02 % para 40 a 49 años). Esto refleja una etapa de estabilidad laboral en comparación con los grupos más jóvenes.
  - En 2024, estas tasas se reducen a 3.79 % para 30 a 39 años y 3.68 % para 40 a 49 años, lo que indica un panorama más favorable para los adultos en edad productiva.
- **Desocupación en los adultos mayores:**
  - En 2004, los grupos de 50 a 59 años, 60 a 69 años y 70 a 79 años tienen tasas de desocupación relativamente bajas, con valores de 5.52 %, 5.15 % y 4.76 %, respectivamente.
  - En 2024, estas tasas disminuyen aún más, llegando a 2.05 % para 50 a 59 años, 2.25 % para 60 a 69 años y 4.35 % para 70 a 79 años. Esto podría deberse a una menor participación activa de estos grupos en el mercado laboral o a un mercado laboral más inclusivo.
  - Para ambos años, no hay desocupados para el grupo 80 a 89, aunque si hay personas económicamente activas. Esto probablemente se debe a que las personas a esa edad deciden trabajar (podrían ser inactivos si lo desearan).

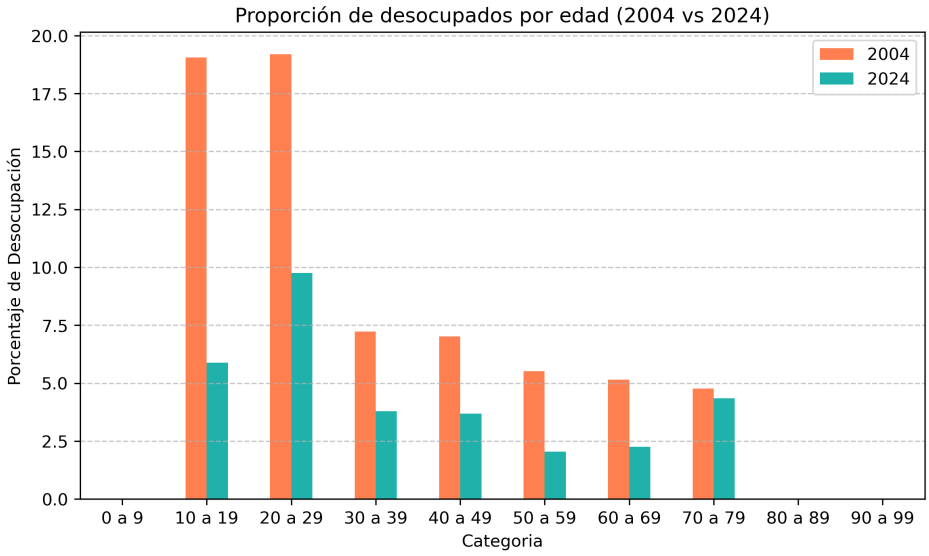


Figura 9: Distribución desocupados por edad (2004 y 2024)

Inciso c

La figura 10 presenta un análisis de las tasas de desocupación por estado civil entre 2004 y 2024 que revela diferencias significativas según las categorías y un descenso generalizado de la desocupación en el período.

- El 3.77 % de las personas económicamente activas en la muestra de la categoría Unido eran desocupados en 2024, mientras que en 2004 fueron 7.89 %.
- El 2.31 % de las personas económicamente activas en la muestra de la categoría Casado eran desocupados en 2024, mientras que en 2004 fueron 5.59 %.
- El 3.49 % de las personas económicamente activas en la muestra de la categoría Separado/a ó divorciado/a eran desocupados en 2024, mientras que en 2004 fueron 10.06 %. 6.82 % de las personas económicamente activas en la muestra de la categoría Viudo/a eran desocupados en 2024, mientras que en 2004 fueron 5.66 %.
- El 7.46 % de las personas económicamente activas en la muestra de la categoría Soltero/a eran desocupados en 2024, mientras que en 2004 fueron 19.08 %.

Se puede apreciar que a disminución de la desocupación es notable en todas las categorías entre 2004 y 2024, salvo un leve aumento en la categoría Viudo/a. Además, las personas solteras y separadas/divorciadas son más vulnerables a la desocupación en ambos años, posiblemente debido a factores como menor estabilidad económica o social. Por último, las personas casadas presentan las tasas más bajas de desocupación en ambos períodos, lo que puede estar asociado con mayores redes de apoyo o estabilidad laboral.

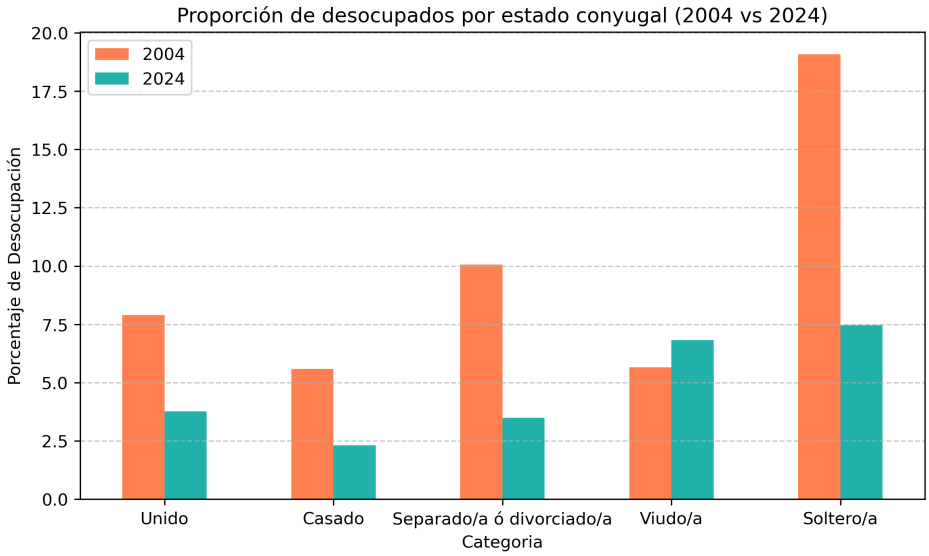


Figura 10: Distribución desocupados por estado conyugal (2004 y 2024)

Ejercicio 10

La figura 11 muestra la comparación entre dos tipos de tasas de desocupación para los años 2004 y 2024: la tasa calculada según la definición del INDEC y una tasa alternativa basada en la economía laboral.

Tasa de Desocupación del INDEC:

- En 2004, la tasa de desocupación según el INDEC fue del 5.26 %, mientras que en 2024 disminuyó al 2.36 %.
- Esto refleja una reducción significativa en el porcentaje de desocupados en relación con la Población Económicamente Activa (PEA), lo que podría estar vinculado a una mejora en las condiciones laborales o a cambios en la estructura económica.

Tasa de Desocupación Alternativa:

- En 2004, la tasa alternativa fue del 3.65 %, disminuyendo al 1.64 % en 2024.
- Este cálculo utiliza como base la Población en Edad de Trabajar (PET), lo que implica un indicador más amplio al no depender exclusivamente de la decisión de participar en el mercado laboral.

La **tasa del INDEC** tiene varias ventajas. En primer lugar, se centra exclusivamente en la población activa, lo que permite un indicador ajustado a las personas que efectivamente están buscando empleo. Además, al ser una medida estándar utilizada internacionalmente, facilita comparaciones entre distintas regiones o países, lo que la convierte en una herramienta práctica para el análisis global del mercado laboral. Sin embargo, también presenta desventajas.

Puede estar sesgada por la decisión endógena de las personas de participar en el mercado laboral. Esto significa que, si la participación en la Población Económicamente Activa (PEA) disminuye, la tasa podría aparentar una mejora aunque las condiciones laborales no necesariamente hayan mejorado.

Por otro lado, la **tasa alternativa** también ofrece ventajas. Una de ellas es que considera a toda la población en edad de trabajar (PET), eliminando el sesgo asociado a las decisiones individuales de participar o no en el mercado laboral. Esto permite una visión más inclusiva y amplia de las condiciones laborales en la economía. Sin embargo, esta medición tiene la desventaja de incluir a individuos que no buscan empleo por elección, lo que podría dar una percepción inflada de la gravedad de la desocupación en ciertos contextos.

Ambas tasas tienen su utilidad dependiendo del enfoque que se desee analizar, y combinarlas puede proporcionar una evaluación más integral del mercado laboral. La diferencia entre ambas tasas sugiere que la medición alternativa proporciona una visión más conservadora

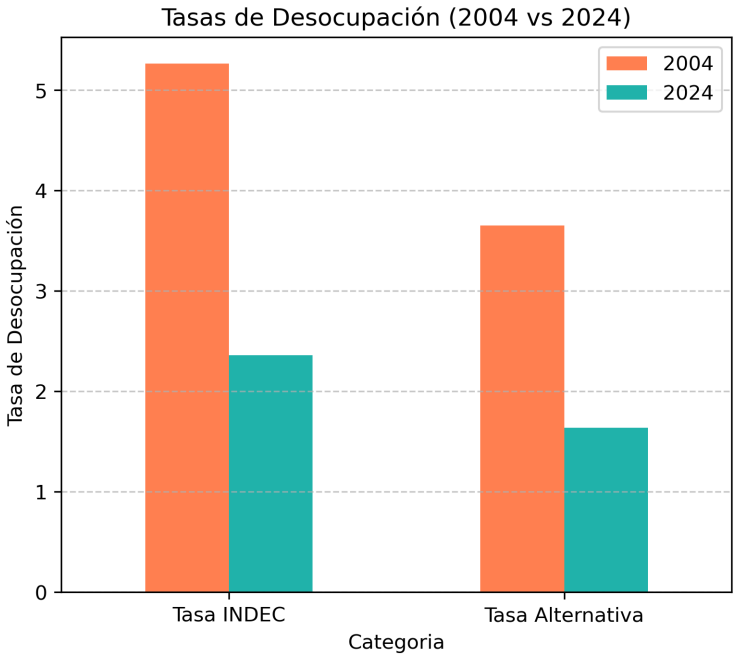


Figura 11: Tasas de desocupación (2004 y 2024)