UNIVERSIDAD DE SAN ANDRÉS

BIG DATA

OTOÑO 2025

TRABAJO PRÁCTICO N°2

CLUSTERS, HISTOGRAMAS Y KERNELS EN LA EPH

Fecha de entrega: viernes 18 de abril a las 23:59hs.

Contenido*:* aplicación de métodos de clustering y métodos no paramétricos a la Encuesta Permanente de Hogares.

Modalidad de entrega

- El informe debe subirse al Campus Virtual en formato PDF con el nombre **Big_Data_TP2_Grupo#**.pdf (donde **#** es el número de grupo), incluyendo gráficos e imágenes dentro del mismo archivo. La extensión máxima es de 8 páginas (sin apéndices) y se espera una redacción clara y precisa.

- Se debe publicar en el repositorio de GitHub de cada grupo el código con los comandos utilizados, indicando claramente a qué inciso corresponde cada uno. El nombre del archivo deberá ser **Big_Data_TP2_Grupo#**.

- **Cualquier detección de copia o plagio será sancionada.**

Parte I: limpieza de la base de datos y la maldición de la multidimensionalidad

La idea de esta primera parte es que completen la limpieza de la base de datos que contiene las observaciones del primer trimestre de 2004 y del primer trimestre de 2024. La base resultante debe incluir todas las variables presentes en ambos trimestres, expresadas de manera homogénea. Es decir, si la variable CH04 en 2004 toma los valores "Hombre" o "Mujer", y en 2024 toma los valores 1 y 2, la variable limpia debe tener solamente dos valores consistentes.

1. ¿Cuál es el tamaño de la de la base de datos para su región con las variables originales unificadas?
2. Como se mencionó en clase magistral, para una mejor interpretación en un futuro, lo ideal es tener una variable dummy por cada categoría de una variable categórica. Si convierten todas las variables categóricas de la EPH en dummies: ¿a qué tamaño se incrementa la dimensión de su base de datos? Se les pide solamente que calculen el valor, no es necesario crear dummies para todas sus variables categóricas.
3. Más adelante en el curso, veremos métodos de selección de variables con aprendizaje automático. Por el momento, para el resto del Trabajo Práctico, seleccionen entre 10 y 20 variables que les parezcan más relevantes. Generen las dummies si las variables elegidas son categóricas.

Parte II: clustering

Esta parte del trabajo práctico tiene como objetivo que realicen un análisis visual de los datos utilizando las herramientas vistas en clase.

1. Comencemos con un análisis que utilice las variables binarias creadas en la Parte I de `CH04`, `CH06`, `CH07`, `CH08`, `NIVEL ED` y las variables que ustedes consideren relevantes para agrupar a personas desocupadas. Quédense únicamente con las observaciones en las que las personas hayan respondido a la pregunta sobre su condición de actividad, o sea, utilicen la base de datos `respondieron` que generaron en el Trabajo Práctico 1.
2. Utilizando solamente el ingreso promedio per cápita y la cantidad de años de educación, realicen un análisis exploratorio aplicando el algoritmo de K-medias.
    a. Corran el algoritmo con $k = 2$, $k = 4$ y $k = 10$, usando `n_init = 20`, y grafiquen los resultados. Interprétenlos.
    b. Grafiquen también los resultados del algoritmo con $k = 2$ junto con la condición real de "ocupado" o "desocupado" (como hicieron en el Trabajo Práctico 1; esta condición puede obtenerse a partir de la variable `ESTADO`). ¿Puede el algoritmo

separar correctamente a las personas ocupadas de las desocupadas? Comenten.

3. Ahora, utilizando todas las variables seleccionadas (incluyendo `CH04`, `CH06`, `CH07`, `CH08`, `NIVEL ED`), realicen un análisis de clustering jerárquico. Expliquen brevemente qué es un dendrograma y qué información nos proporciona. Generen un dendrograma utilizando las variables seleccionadas y coméntenlo.

Parte III: histogramas y kernels

El objetivo de esta parte del trabajo es aplicar los contenidos vistos sobre métodos no paramétricos, tales como histogramas y estimaciones kernel.

1. Para las personas que reportaron su condición de actividad, muestren la distribución del ingreso individual en los años 2004 y 2024 utilizando un histograma. Justifiquen su elección de la cantidad de bins. Comenten los resultados obtenidos. Recuerden realizar un tratamiento de outliers antes de construir estos gráficos.
2. En el siguiente ejercicio, la idea es quedarse con una observación por hogar.
    a. Generen una variable que tome valor 1 si **algún** miembro del hogar se encuentra desocupado, y 0 en caso contrario.
    b. Cree la variable ingreso por hogar con la suma de todos los miembros del hogar ocupados y que reportan un ingreso positivo.
    c. Para cada año, estimen y grafiquen la distribución del ingreso por hogar utilizando un kernel uniforme, separando los casos entre:
        - hogares con al menos una persona desocupada
        - hogares en los que todas las personas están ocupadas.
    d. Utilice el ancho de banda óptimo. ¿Cómo le explicarían a su abuela el trade-off que implica esta elección? Intenten explicarlo con el lenguaje más sencillo posible.
    e. Cuál es la diferencia porcentual entre los hogares sin desocupados y algún desocupado. ¿Se modifica este número entre 2004 y 2024? Comenten.
3. Repitan la estimación de los kernels utilizando un kernel gaussiano y el kernel de Epanechnikov.
    a. Comparen las estimaciones obtenidas con cada uno.
    b. Comenten las diferencias observadas.