

Trabajo Practico Nº2

(Semestre de Otoño 2025)

Big Data

Profesora: María Noelia Romero
Tutor: Tomás Pacheco
Alumnos: Catalina Gallardo, Manuel Elorga

PARTE 1: limpieza de la base de datos y la maldición de la multidimensionalidad

Ejercicio 1

La base de datos tiene 168 columnas.

Ejercicio 2

Si convirtieramos todo a dummies, la base de datos tendría 293 columnas.

Ejercicio 3

Las variables que resultan más relevantes para agrupar a personas desocupadas son:

- **Tamaño del aglomerado urbano (MAS_500)**
- **Área urbana (AGLOMERADO)**
- **Sexo (CH04)**
- **Edad (CH06)**
- **Estado civil (CH07)**
- **Cobertura médica (CH08)**
- **Lugar de nacimiento (CH15)**
- **Lugar de residencia hace cinco años (CH16)**
- **Nivel educativo (NIVEL_ED)**
- **Indica si trabajó en el último año (PP02I)**
- **Indica si trabajó alguna vez (PP10D)**
- **Ingreso per capita familiar (IPCF)**

PARTE 2: Clustering

Ejercicio 2

a)

Para el análisis de k-medias, se definieron dos variables centrales para el análisis de clustering: ingreso individual y años de educación.

- **Eduación**: se calcularon años estándar completados según el nivel educativo (primaria: 6 años, secundaria: 12 años, terciario: 14 años, etc.), ajustando por años aprobados cuando el nivel no estaba finalizado. El resultado es un indicador continuo de formación formal.
- **Ingreso**: se actualizaron los valores a pesos constantes del primer trimestre de 2024.

A partir de estas dos dimensiones se ejecutó K-means con tres valores de K, como se ve en la Figura 1:

- **K = 2**: surge una división clara entre ingresos bajos con menor educación e ingresos altos con mayor formación.
- **K = 4**: la segmentación más rica, con grupos desde muy bajos ingresos y poca educación hasta altos ingresos con formación avanzada.
- **K = 10**: se observa una fragmentación fina que captura diferencias sutiles, pero con mayor riesgo de ruido y menor interpretabilidad.

En resumen, K = 2 y K = 4 ofrecen agrupaciones claras y útiles, mientras que K = 10 aporta más detalle a costa de simplicidad y robustez analítica.

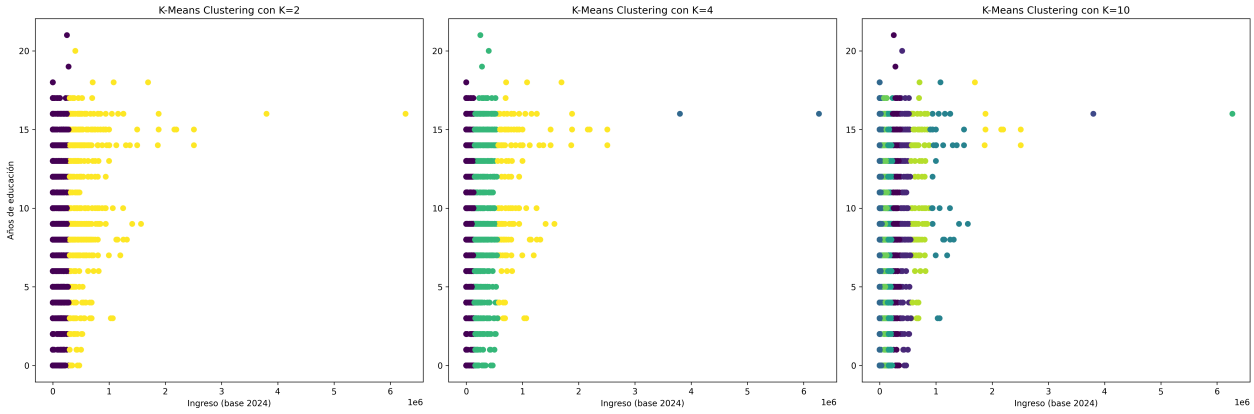


Figura 1: Análisis K-Medias, con k=2, k=4 y k=10

b)

El algoritmo K-means con $k = 2$ logra separar parcialmente a las personas ocupadas de las desocupadas, principalmente en función del ingreso y los años de educación. Se observa que las personas con mayores ingresos y más educación tienden a agruparse en un mismo cluster, generalmente correspondiente a los ocupados. Sin embargo, hay un solapamiento considerable: algunos desocupados tienen características similares a los ocupados y viceversa. Esto muestra que el algoritmo capta ciertas diferencias estructurales, pero no clasifica con precisión la condición laboral, ya que no considera otros factores relevantes.a

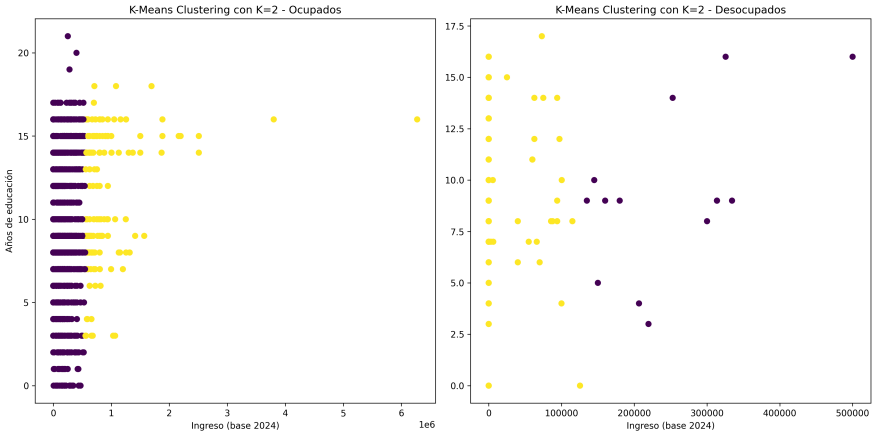


Figura 2: Análisis K-Medias con k=2

Ejercicio 3

Un dendrograma es un diagrama en forma de árbol que muestra cómo, paso a paso, se van uniendo objetos en un análisis de clustering jerárquico. En el eje vertical se representa la "distancia" o disimilitud a la que se fusionan primero pares de observaciones, luego grupos sucesivamente mayores, hasta formar un único clúster. Así, las uniones más bajas indican alta similitud y las más altas revelan diferencias mayores entre los grupos.

La Figura 3 muestra primero fusiones a muy baja distancia, indicando parejas de individuos con perfiles casi idénticos. A distancias intermedias se forman dos grandes ramas: una reúne sobre todo jóvenes sin experiencia ni cobertura, y otra agrupa desocupados con algo de trayectoria y seguro médico. Finalmente, dos casos aislados (outliers) se fusionan al resto a muy alta distancia, señalando perfiles atípicos. Un corte horizontal alrededor de permitiría extraer 4–5 clústeres homogéneos para caracterizar subtipos de desocupación. En este ejercicio se aplica un analisis de clustering jerarquico aglomerativo sobre las personas desocupadas de la base `respondieron`, con el objetivo de identificar subgrupos o patrones homogeneos dentro de la muestra sin necesidad de definir un numero optimo de grupos.

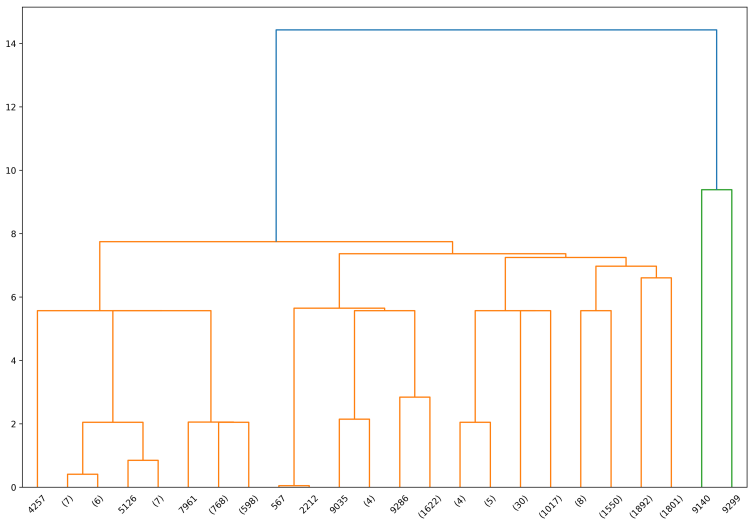


Figura 3: Clustering Jerárquico

PARTE 3: histogramas y kernels

Ejercicio 1

La Figura 4 compara la distribución del ingreso individual (`P47T`) en los años 2004 y 2024. Para no sesgar el análisis, se excluyó de la muestra el cuantil más alto para excluir a las personas con ingresos demasiado grandes. No se excluyen los datos del primer cuantil ya que la distribución está sesgada hacia la izquierda (hay muchos ingresos muy bajos).

En ambos histogramas se optó por utilizar la cantidad de 30 bins para que se pueda identificar todo tipo de picos, asimetrias y modas de los ingresos. Dado que tenemos miles de observaciones cada bin asegura que contenga una cantidad significativa de casos. Ademas, se utilizó la msima cantidad de bins para ambos años para una mejor comprensión de los datos.

Se observa que la distribución para 2004 presenta una mayor cantidad de ingresos bajos. En cambio, para 2024, la distribución se orienta hacia la derecha reflejando un incremento de ingresos individuales. Ademas, se puede observar una mayor heterogeneidad de los datos ya que hay una gran dispersión con una mayor cantidad de valores.

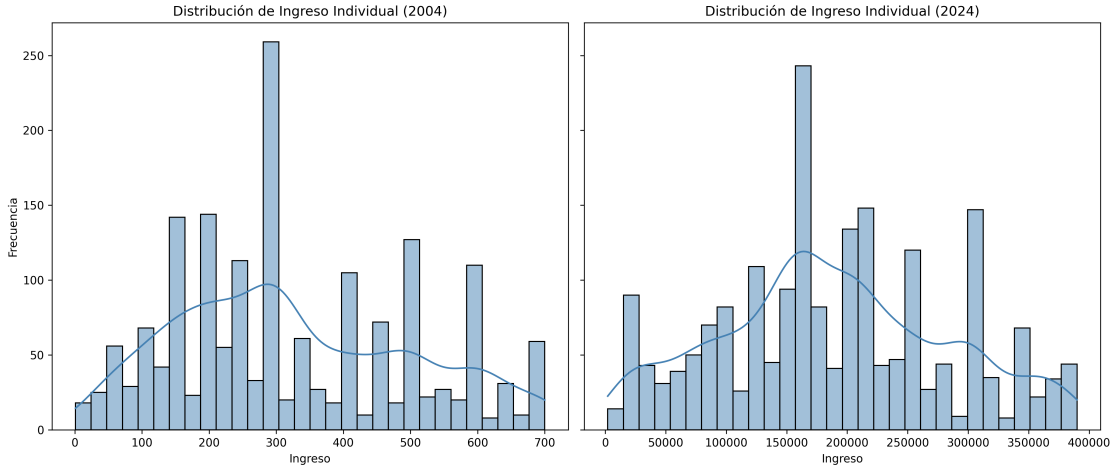


Figura 4: Distribución del Ingreso Individual (2004 vs 2024)

Ejercicio 2

Para este ejercicio se creo una nueva base de datos llamada `hogares` utilizando la variable `CODUSU` que identifica a cada hogar. En la base se agregaron las variable binaria `hay_desocupado` que indica si hay al menos un desocupado en el hogar e `ingreso_hogar` que indica el ingreso total del hogar.

c)

En la Figura 5 (2004), los hogares con al menos una persona desocupada (línea roja) concentran su densidad en ingresos bajos, con mayor variabilidad reflejada en picos pequeños. En contraste, los hogares con todos ocupados (línea verde) presentan ingresos promedio más altos, con una distribución más uniforme y menos oscilaciones.

En la Figura 6 (2024), los hogares desocupados (línea roja) mantienen su concentración en ingresos bajos, pero con un rango de ingresos más amplio y mayor dispersión, indicando persistente desigualdad interna. Los hogares ocupados (línea verde) siguen mostrando ingresos más altos y un incremento general respecto a 2004, aunque la diferencia con los desocupados se mantiene marcada.

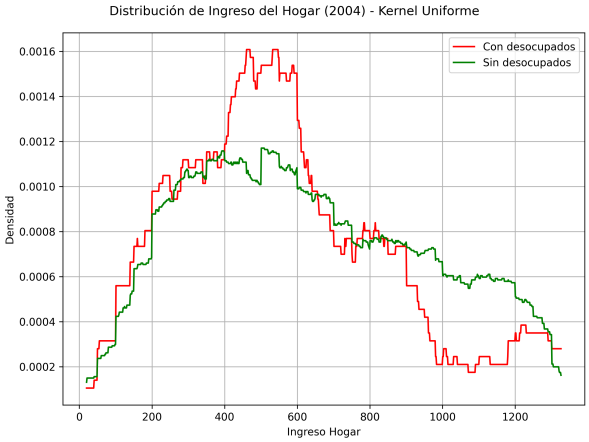


Figura 5: Distribución del Ingreso por Hogar con Kernel Uniforme (2004)

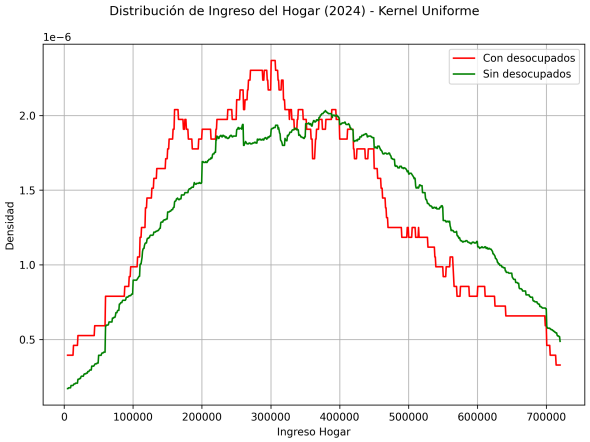


Figura 6: Distribución del Ingreso por Hogar con Kernel Uniforme (2024)

d)

El ancho de banda es el tamaño de la 'ventana' que utilizamos para calcular cuánto influyen unos datos sobre otros, de manera que el resultado sea lo más preciso posible. Para elegir cual es el mejor ancho de banda para utilizar, debemos considerar un trade-off entre sesgo y varianza.

Si elegimos un ancho de banda muy grande, estamos promediando demasiados puntos y se pierden detalles importantes. En cambio, si el ancho de banda es muy pequeño, la estimación se ajusta demasiado a cada punto, lo que significa que se concentra demasiado en las variaciones de cada uno.

El ancho de banda óptimo es ese valor intermedio en el que compensamos la pérdida de detalle (sesgo) y el exceso de variaciones (varianza) para aproximarnos lo mejor posible a la verdadera forma de los datos.

e)

La diferencia porcentual en ingresos entre hogares ocupados y desocupados disminuyó del 38 % en 2004 al 27 % en 2024, lo que indica una reducción en la brecha relativa entre ambos grupos. Esto podría reflejar mejoras en los ingresos de los hogares desocupados, un crecimiento más lento en los ingresos de los ocupados o cambios en las dinámicas laborales y sociales que han mitigado parcialmente el impacto de la desocupación. Sin embargo, aunque la brecha relativa se ha reducido, sigue siendo significativa.

Ejercicio 3

a)

En la Figura 7, la curva de los hogares con desocupados (linea roja) se encuentra desplazada hacia la izquierda con respecto a la de los hogares sin desocupados (linea verde). Esto sugiere que los primeros presentan unos ingresos más bajos. A su vez, se demuestra una mayor dispersión hacia ingresos más elevados.

En la Figura 8, los hogares con desocupados tienden a concentrarse a los niveles más bajos de ingreso. Sin embargo, podemos ver que ambas distribuciones aparecen más suavizadas y desplazadas hacia la derecha respecto a 2004, reflejando un aumento general de ingresos.

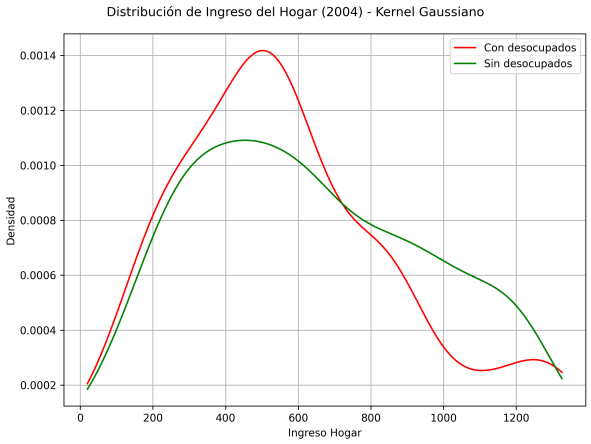


Figura 7: Distribución del Ingreso por Hogar con Kernel Gaussiano (2004)

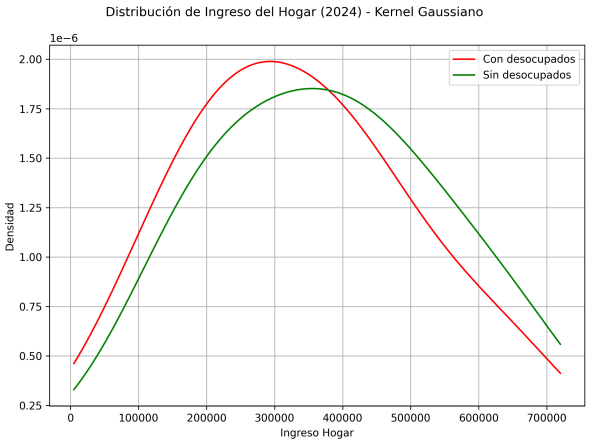


Figura 8: Distribución del Ingreso por Hogar con Kernel Gaussiano (2024)

En la Figura 9, el uso de Epanechnikov genera unos picos mas marcados y cambios bruscos en la densidad. Igualmente, llegamos a la misma conclusión: los hogares con desocupados tienen menores ingresos, con una curva más centrada a la izquierda.

En la Figura 10, la estimación es más irregular que la Gaussiana. Nuevamente, los hogares con ingresos más altos y una densidad más dispersa, mientras los desocupados se concentran en los rangos inferiores de ingresos.

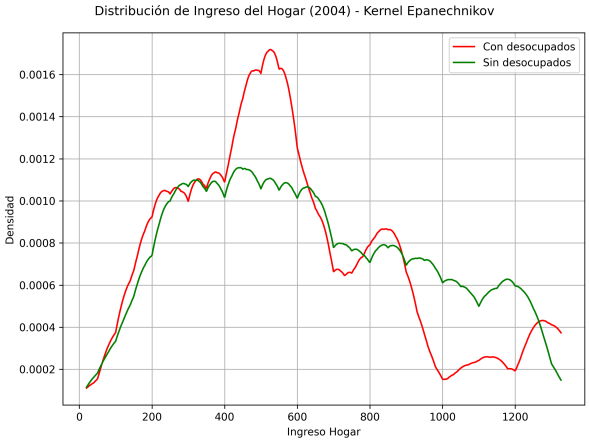


Figura 9: Distribución del Ingreso por Hogar con Kernel Epanechnikov (2004)

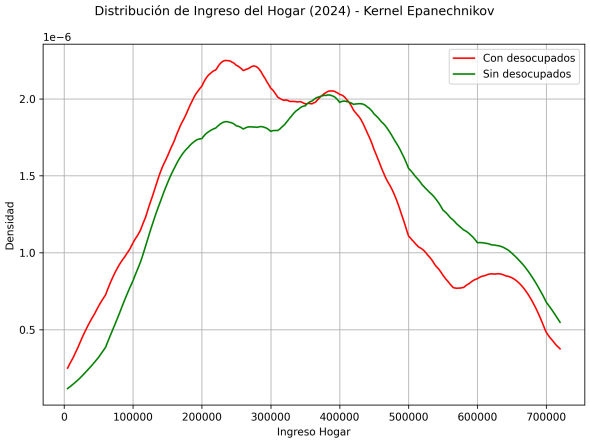


Figura 10: Distribución del Ingreso por Hogar con Kernel Epanechnikov (2024)

b)

El kernel Gaussiano genera curvas más suaves y continuas ya que asigna peso a todos los puntos del dominio. Permite capturar la tendencia general de la distribución del ingreso sin ver ningun cambio abrupto y ver colas más prolongadas.

Por otro lado, el kernel Epanechnikov produce colas más segmentadas y con cambios más abruptos. Es por esto que la estimación es más sensible a pequeñas concentraciones de datos en la que se visualiza picos más marcados.