UNIVERSIDAD DE SAN ANDRÉS

BIG DATA

TRABAJO PRÁCTICO N° 3

CLASIFICANDO DE DESOCUPADOS EN LA EHP

Fecha de entrega: 19 de mayo a las 23:59 hs.

Contenido*:* Continuar con la familiarización con la base de datos de la Encuesta Permanente de Hogares y aplicar los métodos de clasificación vistos en clase.

Modalidad de entrega

- El informe debe subirse al Campus Virtual en formato PDF con el nombre **Big_Data_TP3_Grupo#**.pdf (donde **#** es el número de grupo), incluyendo gráficos e imágenes dentro del mismo archivo. La extensión máxima es de 6 páginas (sin apéndices) y se espera una redacción clara y precisa.

- Se debe publicar en el repositorio de GitHub de cada grupo el código con los comandos utilizados, indicando claramente a qué inciso corresponde cada uno. El nombre del archivo deberá ser **Big_Data_TP3_Grupo#**.

- **Cualquier detección de copia o plagio será sancionada.**

El objetivo de este trabajo práctico es intentar predecir si una persona está desocupada o no utilizando distintas variables de características individuales y los distintos clasificadores vistos en clase. Recuerden que en los trabajos prácticos anteriores crearon dos bases de datos distintas: `respondieron`, que tiene datos de personas que sí respondieron su condición de empleo y `norespondieron`, que tienen aquellas personas que no declaran estar desempleadas o empleadas.

A. Un poco más de estadística descriptiva

1. Seleccionen distintas variables que consideren que pueden ser importantes a la hora de predecir la condición de ocupación de una persona. Deben seleccionar variables de la base y crear otras variables (como la edad al cuadrado, los años de educación, etc.). Para cada una de las variables creadas, grafíquenlas y comenten los resultados. Argumenten brevemente (2-3 oraciones) por qué cada una de estas variables puede ayudar a la clasificación.

> **Importante**: Se valorará la creatividad a la hora de crear variables continuas. Para estas, recomendamos hacer un histograma y/o estimar la densidad a través de un kernel de variables continuas. Si deciden hacer variables categóricas, es incorrecto hacer un scatter plot o histogramas. Pueden incluir las variables creadas en trabajos anteriores, como la cantidad de años de educación o incorporar alguna variable de manera no lineal (como edad al cuadrado, por ejemplo). No hay un máximo preestablecido de variables a elegir.

B. Enfoque de validación

Utilicen la base `respondieron`. Para cada año, dividan las observaciones en una base de prueba (test) y una de entrenamiento (train) utilizando el comando `train_test_split`. La base de entrenamiento debe comprender el 70% de los datos, y la semilla a utilizar (*random state instance*) debe ser 444. Establezca a desocupado como su variable dependiente en la base de entrenamiento (vector y). El resto de las variables seleccionadas serán las variables independientes (matriz X). Recuerden agregar la columna de unos (1).

2. Cree una tabla de diferencia de medias entre la base de entrenamiento y la de testeo de las características seleccionadas en su matriz X. Comente la tabla de la diferencia de medias de sus variables entre entrenamiento y testeo.

C. Métodos de Clasificación y Performance

3. Implementen los siguientes métodos reportando luego la matriz de confusión, la curva ROC, los valores de AUC y de Accuracy de cada uno:
    - Regresión logística
    - Análisis discriminante lineal
    - Análisis discriminante cuadrático
    - KNN con K=5
    - Naive Bayes
4. Compare los resultados de 2004 versus 2024. ¿Cuál de los métodos predice mejor en cada año? Justifiquen detalladamente utilizando las medidas de precisión que conocen.
5. Con el método que seleccionaron, predigan qué personas son desocupadas dentro de la base `norespondieron`. ¿Qué proporción de las personas que no respondieron pudieron identificar como desocupadas?