

Trabajo Práctico Nº3

(Semestre de Otoño 2025)

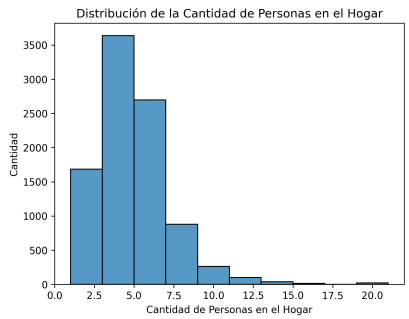
Big Data

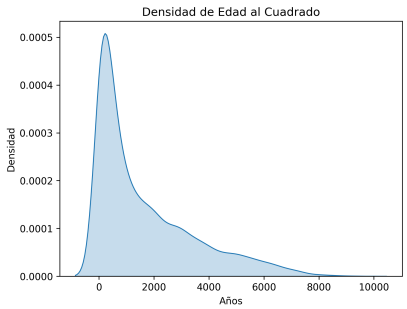
Profesora: María Noelia Romero
Tutor: Tomás Pacheco
Alumnos: Catalina Gallardo, Manuel Elorga

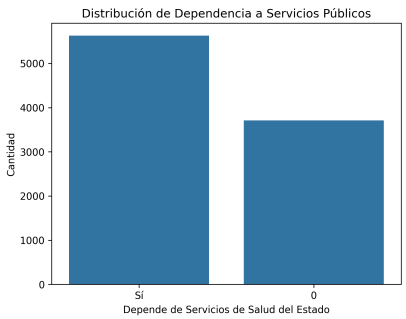
1. Un poco más de estadística descriptiva

Ejercicio 1

- **Sexo** (`CH04`): indica el sexo del individuo. Es útil para considerar posibles disparidades de género en el acceso y permanencia en el mercado laboral.
- **Edad** (`CH06`): registra la edad del individuo. Es relevante para distinguir entre población activa e inactiva, y detectar patrones etarios en la desocupación.
- **Estado civil** (`CH07`): refleja la situación conyugal del individuo. Puede ser relevante si la desocupación afecta de forma distinta a personas solteras, casadas, divorciadas o viudas.
- **Lugar de residencia hace cinco años** (`CH16`): informa dónde vivía la persona cinco años antes de la encuesta. Permite identificar movilidad geográfica (dentro del país o desde el exterior), lo cual puede incidir en las posibilidades de inserción laboral, acceso a redes de empleo y adaptación al mercado de trabajo local.
- **Cantidad de personas en el hogar** (`PERSONAS_HOGAR`): indica cuántas personas viven en el hogar del encuestado. Puede estar relacionada con la presión económica del hogar y la necesidad de que sus miembros participen del mercado laboral. Como se puede ver en el primer gráfico, se presenta una distribución sesgada hacia la derecha en la que los hogares poseen entre 2 a 6 miembros. Sin embargo, existen valores extremos que hacen que aumente la varianza.
- **Edad al cuadrado** (`EDAD2`): corresponde al cuadrado de la edad del individuo. Permite capturar posibles efectos no lineales de la edad sobre la condición de ocupación, como diferencias entre jóvenes, adultos y personas próximas a la jubilación. Como se puede ver en el segundo gráfico, hay una curtósis alta y una cola larga. Confirma que la muestra es relativamente joven.
- **Obra social** (`OBRA_SOCIAL`): variable binaria que toma valor 0 si la persona depende total o parcialmente de los servicios públicos de salud. Puede ser un buen predictor de ocupación, ya que contar con obra social suele estar vinculado a una relación laboral formal. En el tercer gráfico, se visualiza que aproximadamente el 60 % de los individuos carece de obra social privada.

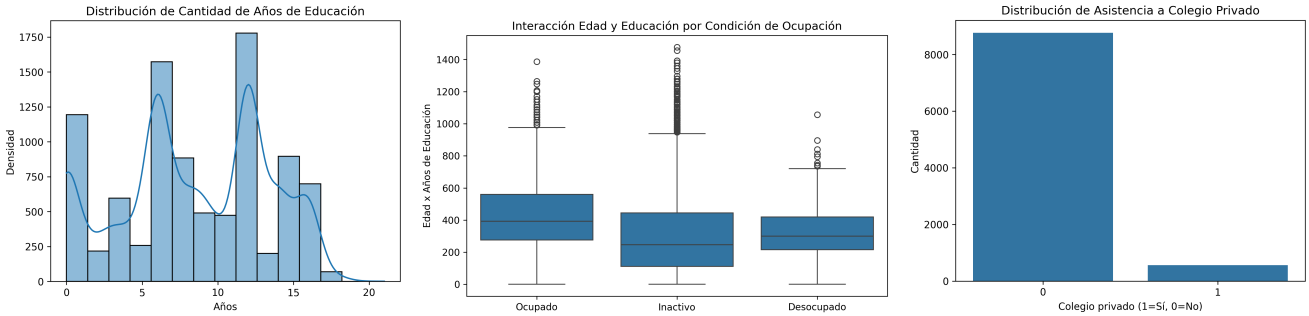






- **Años de educación** (`EDUCACION`): estima la cantidad de años de educación formal del individuo. Fue ajustada para reducir valores perdidos. Esta variable es clave, ya que el nivel educativo influye fuertemente en las oportunidades laborales y la probabilidad de inserción en el mercado formal. En el primer gráfico se puede ver un patrón en las personas que tienen la primaria completa, secundaria completa y estudios superiores. Es una buena evidencia para evidenciar la heterogeneidad en el capital humano.

- **Interacción entre edad y educación** (`EDADxEDUCACION`): representa el producto entre edad y años de educación. Busca capturar efectos combinados, como que una mayor edad acompañada de mayor nivel educativo se traduzca en más experiencia y, por tanto, mayor probabilidad de empleo. El segundo gráfico muestra que la interacción entre los valores medianos de los ocupados es más alta que la de los desocupados. Esto sugiere que una mayor formación y experiencia incrementa su empleabilidad.
- **Educación en colegio privado** (`COLEGIO_PRIVADO`): variable binaria que indica si el individuo asistió a una institución educativa privada. Puede utilizarse como proxy del nivel socioeconómico del hogar de origen, lo que incide en las trayectorias educativas y laborales futuras. En el ultimo gráfico, vemos que la gran mayoría asistió a una institución educativa pública, con solo el 10 % de la muestra reportando haber asistido a un colegio privado.



2. Enfoque de validación

Ejercicio 2

La Tabla 1 presenta un análisis de las diferencias de medias entre la base de entrenamiento (*train*) y la base de prueba (*test*) para las variables elegidas en los años 2004 y 2024. El objetivo es verificar que la partición de los datos realizada con el comando `train_test_split` fue aleatoria y que ambas muestras son comparables.

Las diferencias de medias entre *train* y *test* son en general muy pequeñas, lo cual indica un buen balance. Por ejemplo, variables como `CH04` (SEXO), `CH07` (ESTADO CIVIL), `PERSONAS_HOGAR`, `OBRA_SOCIAL` y `COLEGIO_PRIVADO` presentan diferencias nulas o cercanas a cero, lo cual es esperable en una partición aleatoria.

En 2004, algunas variables muestran diferencias algo mayores, como `EDAD2` (-54.58) y `EDUCACION` (0.41). No obstante, en el caso de `EDAD2`, esto puede explicarse por una pequeña diferencia en la edad promedio (`EDAD`), amplificada por la transformación cuadrática. En cuanto a `EDUCACION`, si bien la diferencia es la más elevada en términos absolutos, sigue siendo pequeña y no se considera problemática.

En 2024, las diferencias son aún menores. La mayor corresponde a `CH06` (EDAD) (-0.44), mientras que `EDAD2` y `EDUCACION` presentan diferencias de -11.72 y -0.09, respectivamente, todas dentro de márgenes aceptables. Variables como `EDADxEDUCACION` (-4.06) también muestran ligeras diferencias, pero no significativas.

En conclusión, todas las diferencias observadas son pequeñas y no estadísticamente significativas.

Esto confirma que la división entre las bases de entrenamiento y prueba fue adecuada y que ambas muestras son representativas del total. Por lo tanto, pueden ser utilizadas sin inconvenientes en el desarrollo y validación de modelos predictivos de la condición de ocupación.

Cuadro 1: Medias y diferencias muestras de entrenamiento y testeo - 2004 y 2024

	2004			2024		
Variable	Media Train	Media Test	Diferencia	Media Train	Media Test	Diferencia
CONSTANTE	1.00	1.00	0.00	1.00	1.00	0.00
SEXO	1.52	1.52	0.00	1.52	1.53	-0.01
EDAD	31.29	31.61	-0.32	36.22	36.66	-0.44
ESTADO CIVIL	3.67	3.63	0.04	3.55	3.51	0.04
DONDE VIVE	1.47	1.50	-0.03	1.31	1.26	0.05
PERSONAS HOGAR	4.83	4.88	-0.04	4.06	4.11	-0.05
$EDAD^2$	1430.17	1484.76	-54.58	1834.88	1846.60	-11.72
OBRA SOCIAL	0.56	0.56	-0.00	0.65	0.64	0.01
EDUCACION	7.92	7.51	0.41	9.06	9.15	-0.09
EDADxEDUCACION	279.93	273.28	6.64	367.69	371.75	-4.06
COLEGIO PRIVADO	0.06	0.05	0.01	0.06	0.06	0.00

3. Métodos de Clasificación y Performance

Ejercicio 3

Para 2004, el Cuadro 2 y la Figura 1 reportan las matrices de confusión y curvas ROC de cada modelo. Abajo, agregamos los *accuracy scores* y los valores de AUC:

Regresión logística: tiene un *accuracy score* de 0.9544 y un AUC de 0.7631.

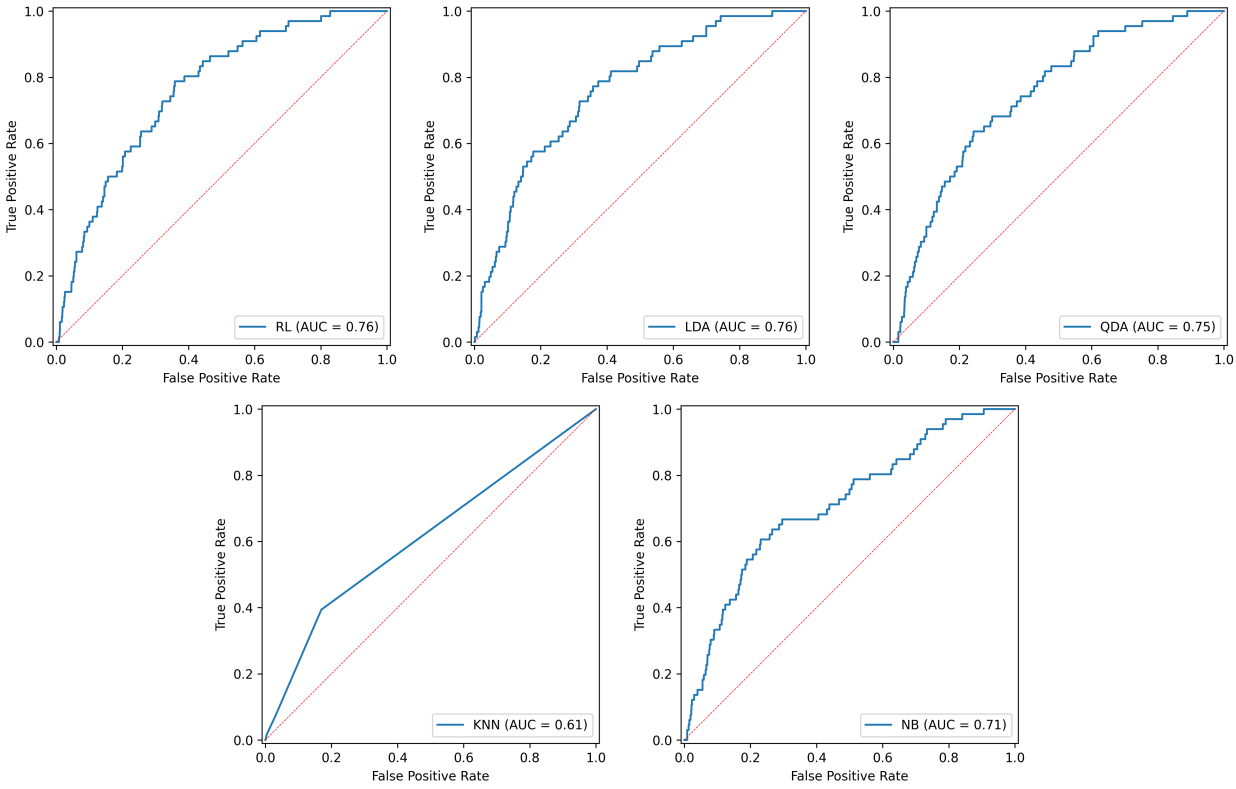
Análisis discriminante lineal (LDA): tiene un *accuracy score* de 0.9544 y un AUC de 0.7643.

Análisis discriminante cuadrático (QDA): tiene un *accuracy score* de 0.7630 y un AUC de 0.7508.

K-Vecinos con K=5: tiene un *accuracy score* de 0.9509 y un AUC de 0.5829.

Naive Bayes: tiene un *accuracy score* de 0.8252 y un AUC de 0.7178.

Figura 1: Curvas ROC - 2004



Cuadro 2: Matrices de Confusión - 2004

	Linear Regression		**LDA**		**QDA**	
	Pred 0	Pred 1	Pred 0	Pred 1	Pred 0	Pred 1
Real 0	1381	0	1381	0	1065	316
Real 1	66	0	66	0	27	39

	KNN		**NB**	
	Pred 0	Pred 1	Pred 0	Pred 1
Real 0	1375	6	1162	219
Real 1	65	1	34	32

Para 2024, el Cuadro 3 y la Figura 2 reportan las matrices de confusión y curvas ROC de cada modelo. Abajo, agregamos los *accuracy scores* y los valores de AUC:

Regresión logística: tiene un *accuracy score* de 0.9815 y un AUC de 0.8677.

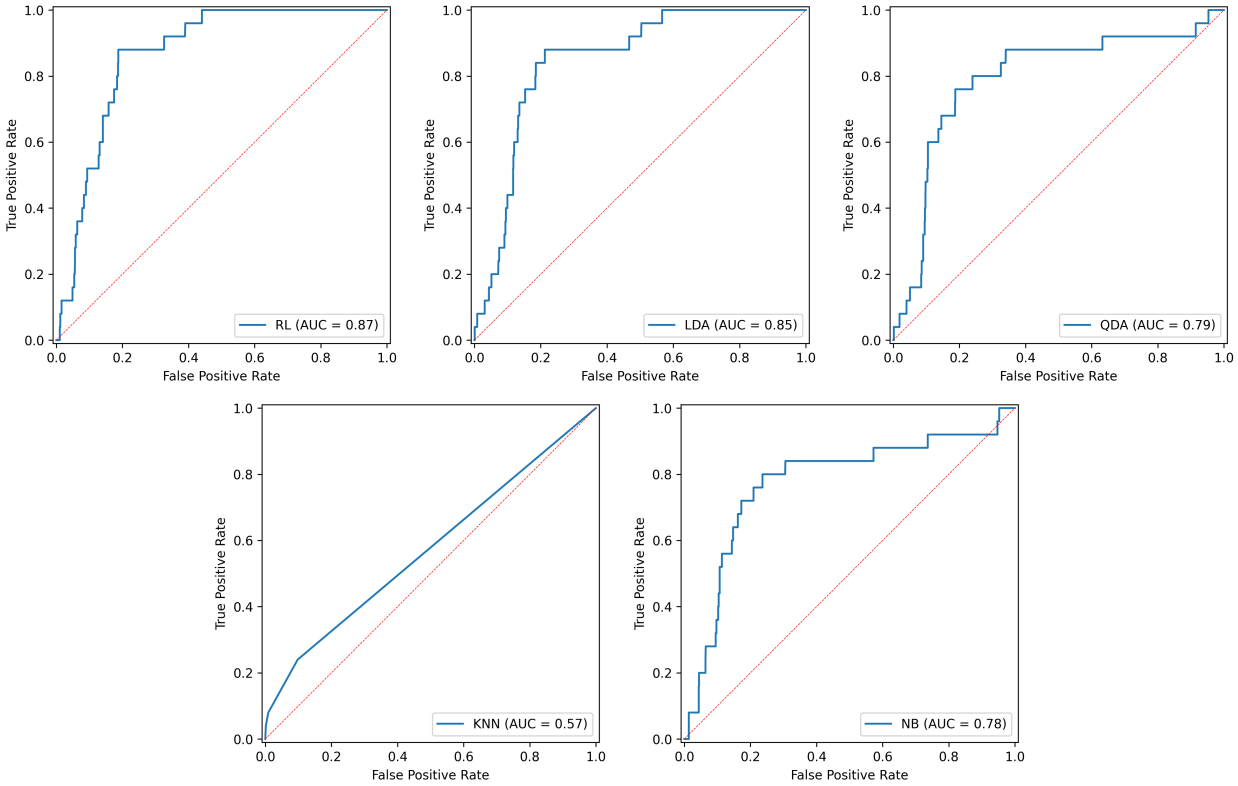
Análisis discriminante lineal (LDA): tiene un *accuracy score* de 0.9815 y un AUC de 0.8670.

Análisis discriminante cuadrático (QDA): tiene un *accuracy score* de 0.8234 y un AUC de 0.8121.

K-Vecinos con K=5: tiene un *accuracy score*: 0.9815 y un AUC de 0.5262.

Naive Bayes: tiene un *accuracy score* de 0.8647 y un AUC de 0.7775.

Figura 2: Curvas ROC - 2024



Cuadro 3: Matrices de Confusión - 2024

	Linear Regression		**LDA**		**QDA**	
	Pred 0	Pred 1	Pred 0	Pred 1	Pred 0	Pred 1
Real 0	1328	0	1328	0	1096	232
Real 1	25	0	25	0	7	18

	KNN		**NB**	
	Pred 0	Pred 1	Pred 0	Pred 1
Real 0	1328	0	1155	173
Real 1	25	0	10	15

Ejercicio 4

Para determinar qué método predice mejor en cada año, es importante analizar varias métricas que reflejan el desempeño del modelo, sobre todo considerando que la clase desocupado es minoritaria y los datos están desbalanceados. Las métricas más relevantes para esta tarea son el *recall*, la precisión, el *F1-score*, el área bajo la curva ROC y la matriz de confusión. Otra medida relevante en este sentido es el *Mean Square Error*, que indica los errores cometidos en la predicción.

En el año 2004, los métodos de regresión logística y análisis discriminante lineal tienen un alto *accuracy* (aproximadamente 95 %) y alta precisión, pero un *recall* de 0 para la clase desocupado (ya que nunca predice 1). El método de vecinos cercanos también presenta un *recall* muy bajo, casi nulo. El *MSE* más bajo entre los modelos se encuentra en el modelo RL. Sin embargo, esto se debe a que el modelo nunca predice 1 y su error son todos los desocupados (a los que se les asigno no desocupados en la predicción). Por otro lado, Naive Bayes muestra un *recall* de 0.485 y un *F1-score* de 0.202, lo que refleja un mejor equilibrio entre detectar desocupados y evitar falsos positivos que los métodos anteriores. Sin embargo, el método que logra el mejor *recall* es QDA, con un 0.591, es decir, identifica un mayor porcentaje de desocupados, aunque su precisión es baja y el *F1-score* es moderado, lo que indica que comete más errores clasificando ocupados como desocupados. En conclusión, para 2004, el equilibrio entre precisión y *recall* se alcanza con Naive Bayes. Sin embargo, como lo que buscamos es predecir desocupados, QDA parecería ser la mejor opción (aunque se cometerán errores de sobrestimación de desocupación).

En el año 2024, nuevamente RL, LDA y KNN presentan un *accuracy* muy alto (cerca del 98 %) pero un *recall* igual a 0 para la clase desocupado, por lo que nunca predicen 1. Naive Bayes mejora el *recall* a 0.6 con un *F1-score* de 0.141, mostrando una mejor capacidad para detectar desocupados que RL, LDA y KNN. De nuevo, RL tiene el menos *MSE*. Similar al 2004, QDA tiene el *recall* más alto, de 0.72, identificando el 72 % de los desocupados, aunque con un *F1-score* ligeramente menor debido a su baja precisión. Por lo tanto, en 2024, QDA es el método que mejor detecta la clase desocupado debido a su alto *recall*, mientras que Naive Bayes ofrece un mejor balance entre precisión y *recall*.

En problemas con clases desbalanceadas, como este, el *recall* y el *F1-score* son métricas más informativas que el *accuracy*, ya que este último puede ser engañoso si el modelo predice principalmente la clase mayoritaria.

Ejercicio 5

Al no tener observaciones de la base `norespondieron` en 2004, predecimos únicamente en 2024. Vamos a utilizar dos métodos: QDA (que es el mejor prediciendo desocupados, pero sobreestima) y RL (que es el que menor error cuadrático medio tiene, pero subestima). El modelo QDA predice que, de los que no respondieron, 50.0 % serán desocupados. Por otro lado, el modelo de regresión logística predice que, de los que no respondieron, 0 % serán desocupados. Vemos que en esta muestra también cumple que el modelo RL no predice ningún desocupado y que el QDA (probablemente) sobreestima. Es importante considerar que estas estimaciones no son muy representativas ya que la muestra tiene solo 6 observaciones.