UNIVERSIDAD DE SAN ANDRÉS

BIG DATA

TRABAJO PRÁCTICO N° 4

CLASIFICANDO DE DESOCUPADOS EN LA EHP: MÉTODOS DE REGULARIZACIÓN Y CART

Fecha de entrega: 5 de junio a las 23:59 hs.

Contenido*:* Continuar con la familiarización con la base de datos de la Encuesta Permanente de Hogares y aplicar los métodos de regresión vistos en clase.

Modalidad de entrega

- El informe debe subirse al Campus Virtual en formato PDF con el nombre **Big_Data_TP4_Grupo#**.pdf (donde **#** es el número de grupo), incluyendo gráficos e imágenes dentro del mismo archivo. La extensión máxima es de 7 páginas (sin apéndices) y se espera una redacción clara y precisa.

- Se debe publicar en el repositorio de GitHub de cada grupo el código con los comandos utilizados, indicando claramente a qué inciso corresponde cada uno. El nombre del archivo deberá ser **Big_Data_TP4_Grupo#**.

- **Cualquier detección de copia o plagio será sancionada.**

El objetivo de este trabajo es evaluar la predicción de desocupados utilizando técnicas de regularización y de árboles. Van a utilizar las mismas bases `X_train`, `y_train`, `X_test`, `y_test` para cada año que crearon en el TP3.

A. Métodos de regularización

1. En el contexto de regresiones LASSO y Ridge, expliquen cómo elegirían el parámetro λ mediante cross validation. Detallen por qué no usarían el conjunto de prueba (test) para tomar esa decisión.

2. En cross validation, ¿cuáles son las implicancias de usar un número de pliegues k muy pequeño o muy grande? Cuando $k = n$ (donde n es el número de muestras), ¿cuántas veces se estima el modelo?

3. Implementen penalizaciones L1 (LASSO) y L2 (Ridge) para regresión logística[1] usando la opción `penalty` y reporten para cada año:
   - La matriz de confusión
   - La curva ROC
   - El valor de AUC
   - El valor de *Accuracy*

   ¿Cómo cambiaron los resultados con respecto al TP3? ¿Mejoró o empeoró la performance de la regresión logística al aplicar regularización?

4. Realicen un barrido de $\lambda = 10^n$ con $n \in \{-5, -4, -3, \ldots, +4, +5\}$ y usen validación cruzada de 10 folds para elegir el λ óptimo en regresión logística con Ridge y con LASSO.

   - ¿Qué valor de λ seleccionó cada método?
   - Generen un gráfico de puntos conectados en donde muestren el promedio MSE test de los folds para cada valor de λ.
   - Además, para LASSO, generen un gráfico de líneas (line plot) que represente el promedio de la proporción de variables descartadas (coeficiente = 0) en función de λ.[2]

5. Para el valor óptimo de λ de LASSO hallado en el inciso anterior, ¿qué variables fueron descartadas? ¿Son las que esperaban?
6. Utilizando la especificación con el λ óptimo, comparen los resultados de LASSO y Ridge para 2004 versus 2024. ¿Qué método de regularización funcionó mejor? Comenten mencionando el MSE de testeo.

---

[1] En la tutorial vimos regularización en regresión lineal con variable dependiente numérica; aquí usamos regresión logística porque la variable dependiente es binaria: "ocupado" o "desocupado").

[2] Deberían observar que a mayor penalidad, esperamos que más coeficientes sean cero, dando una curva en forma de "S".

B. Árboles

7. Para cada uno de los años estimen un árbol de decisión (CART) eligiendo el hiperparámetro de profundidad del árbol (`max_depth`) con 10-fold Cross-Validation. Muestren los gráficos de árboles que obtuvieron para cada año y compárenlos.
8. Muestren en un gráfico la importancia de cada uno de los predictores. ¿Podría decirse que los coeficientes de las variables menos importantes son los que LASSO "achicó" a cero?
9. Computen la matriz de confusión, la curva ROC, el AUC y el *accuracy*. Comparen los árboles entre años y con las predicciones hechas usando LASSO y Ridge. ¿Qué pueden decir del trade-off entre comunicación de los resultados y performance predictiva? En este caso, ¿hay una ventaja por utilizar un método no lineal? Incorporen el MSE test dentro de la justificación.