Trabajo Práctico N°5

(Semestre de Otoño 2025)

Big Data

Profesora: María Noelia Romero

Tutor: Tomás Pacheco

Alumna: Catalina Gallardo

Construcción de funciones y sistematización de métodos

El análisis de los modelos de clasificación aplicados a los datos de 2004 y 2024 revela patrones consistentes y algunas diferencias menores entre ambos años. En términos generales, los modelos presentan un buen desempeño en exactitud, pero serias limitaciones para identificar correctamente la clase minoritaria (desocupados), que es la variable de interés.

En 2004, los modelos Logit, LDA, LASSO, AdaBoost y Random Forest no logran predecir correctamente ningún caso de desocupación. La única excepción parcial es KNN, que identifica dos casos positivos, aunque a costa de siete falsos positivos. Esta situación se refleja en las métricas: el *accuracy* (0.95) y el MSE (0.05) se mantienen constantes en casi todos los modelos, pero tanto la precisión como el *recall* son nulos, salvo en el caso de KNN. El AUC varía ligeramente: alcanza 0.77 con Random Forest, 0.76 con Logit y LDA, y desciende a 0.50 con AdaBoost, lo que refleja la falta de capacidad discriminativa de este último. Todos estos resultados se resumen en el Cuadro 1.

En 2024, los valores de exactitud mejoran levemente a 0.98 y el MSE disminuye a 0.02, lo que podría interpretarse como una mejora global en la capacidad predictiva. Sin embargo, esta mejora se debe a la sobrerrepresentación de la clase negativa, ya que ningún modelo logra clasificar correctamente a los individuos desocupados. En todos los casos, la matriz de confusión presenta ceros en la columna de verdaderos positivos, por lo que las métricas de precisión y *recall* permanecen en cero. No obstante, se observan valores elevados de AUC en algunos modelos: Logit (0.87), LDA (0.86), LASSO (0.84) y Random Forest (0.81). Esto indica que los modelos sí asignan probabilidades distintas a las dos clases, pero que bajo el umbral de decisión estándar (0.5) no se produce una clasificación efectiva. Los resultados se detallan en el Cuadro 2.

Las Figuras 1 y 2 presentan las curvas ROC correspondientes a cada año. A pesar de que algunos modelos logran áreas bajo la curva razonables, estos valores no se traducen en un buen desempeño clasificador, lo cual sugiere que el problema central reside en el severo desbalance de clases. Este desbalance dificulta el aprendizaje de patrones útiles para identificar la clase minoritaria.

En conclusión, si bien los modelos muestran un buen rendimiento en métricas globales, todos fallan en el objetivo principal: detectar a los desocupados. Es posible que se necesite un modelo más completo y una base de datos con una mayor cantidad de desocupados —y un n mayor en general— para lograr una mejor predicción.

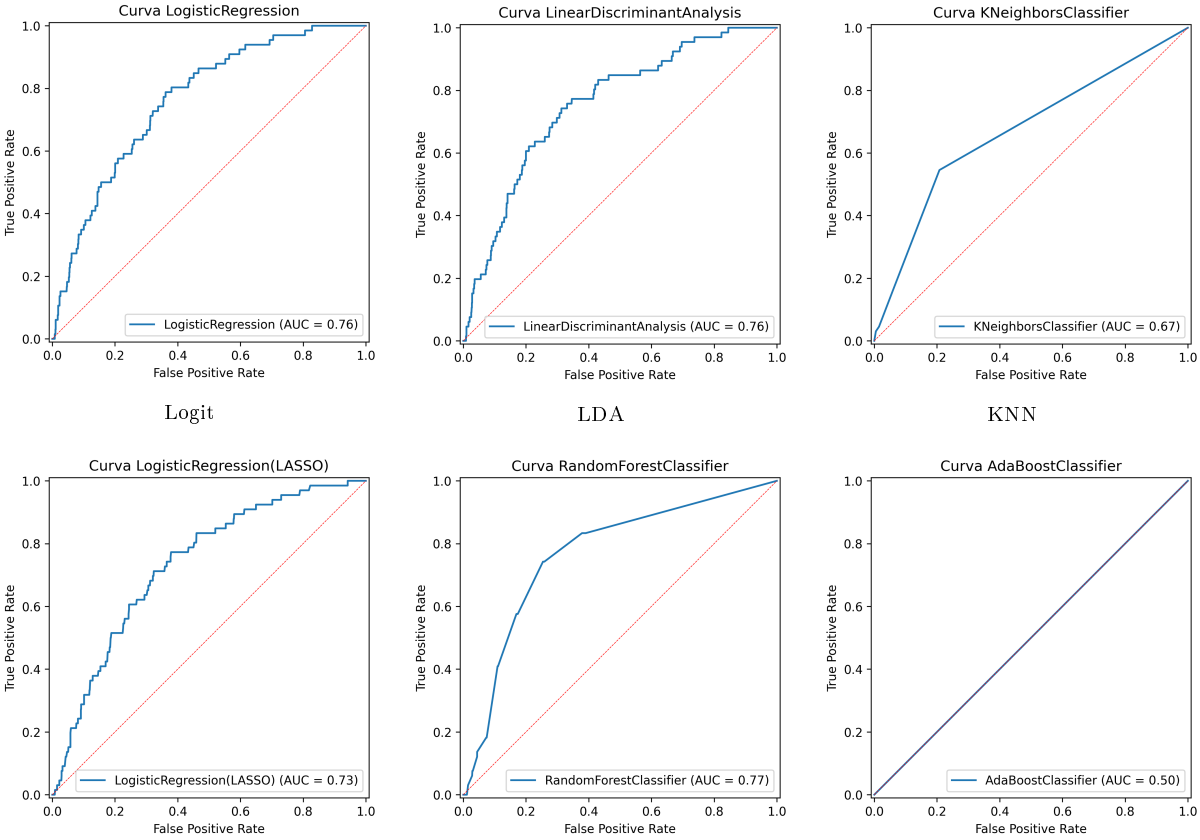
Table 1: Resultados de los modelos para el año 2004.

Modelo	Hiperparámetros	Matriz	Acc.	Prec.	Rec.	MSE	AUC
LogisticRegression	penalty=None	[[1381, 0] [66, 0]]	0.95	0.00	0.00	0.05	0.76
LinearDiscriminantAnalysis	—	[[1381, 0] [66, 0]]	0.95	0.00	0.00	0.05	0.76
KNeighborsClassifier	n_neighbors=7	[[1374, 7] [64, 2]]	0.95	0.22	0.03	0.05	0.67
LogisticRegression (LASSO)	C=0.1, penalty=l1, solver=liblinear	[[1381, 0] [66, 0]]	0.95	0.00	0.00	0.05	0.73
RandomForestClassifier	max_features=3, max_samples=0.25, n_estimators=25	[[1378, 3] [66, 0]]	0.95	0.00	0.00	0.05	0.77
AdaBoostClassifier	learning_rate=0.001, n_estimators=25	[[1381, 0] [66, 0]]	0.95	0.00	0.00	0.05	0.50

Table 2: Resultados de los modelos para el año 2024.

Modelo	Hiperparámetros	Matriz	Acc.	Prec.	Rec.	MSE	AUC
LogisticRegression	penalty=None	[[1328, 0] [25, 0]]	0.98	0.00	0.00	0.02	0.87
LinearDiscriminantAnalysis	—	[[1328, 0] [25, 0]]	0.98	0.00	0.00	0.02	0.86
KNeighborsClassifier	—	[[1328, 0] [25, 0]]	0.98	0.00	0.00	0.02	0.69
LogisticRegression (LASSO)	C=0.1, penalty=l1, solver=liblinear	[[1328, 0] [25, 0]]	0.98	0.00	0.00	0.02	0.84
RandomForestClassifier	max_features=3, max_samples=0.25, n_estimators=75	[[1328, 0] [25, 0]]	0.98	0.00	0.00	0.02	0.81
AdaBoostClassifier	learning_rate=0.001, n_estimators=25	[[1328, 0] [25, 0]]	0.98	0.00	0.00	0.02	0.50

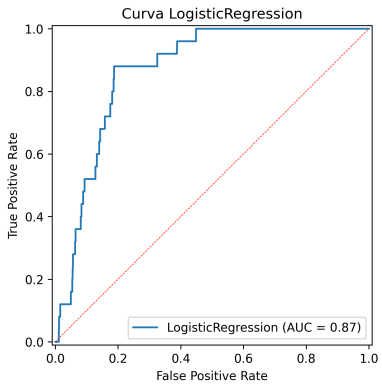
Nota: de los dos métodos de boosting evaluados (AdaBoost y Gradient Boosting), la función `evalua_multiples_metodos` reporta únicamente el de menor MSE. Una celda vacía en la columna de hiperparámetros indica que el modelo se estimó con los valores por defecto.



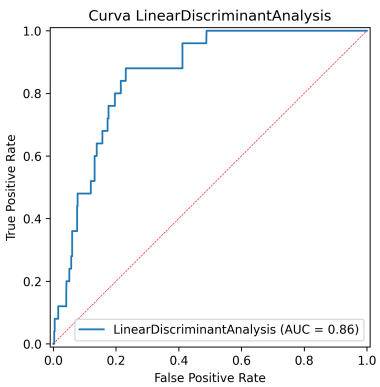
Logit | LDA | KNN

LASSO | Random Forest | AdaBoost

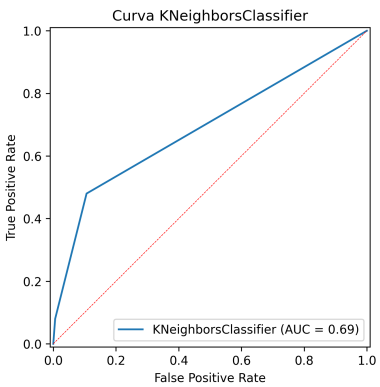
Figure 1: Curvas ROC, 2004.



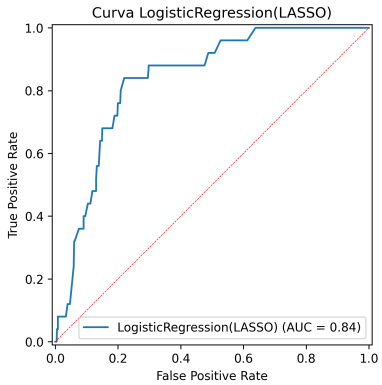
Logit



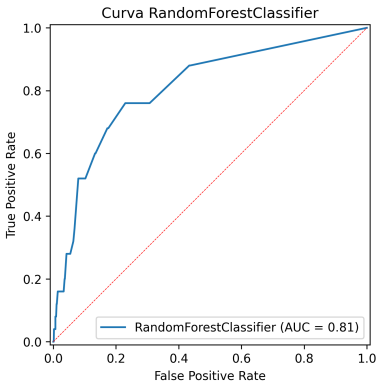
LDA



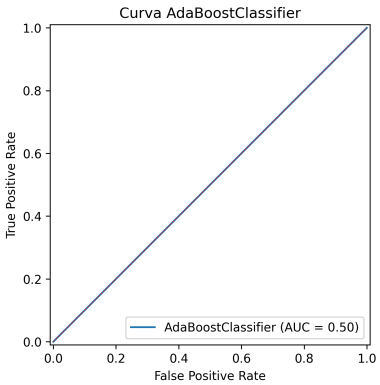
KNN



LASSO



Random Forest



AdaBoost

Figure 2: Curvas ROC, 2024.